Llenguatges de marques

Xavier Sala

Llenguatges de marques i sistemes de gestió d'informació

Índex

Introducció

Els llenguatges de marques estan en plena expansió. Recolzant-se en el gran èxit que han representat les pàgines web han anat apareixent noves tecnologies basades en llenguatges de marques que permeten als usuaris i als programes aconseguir resultats amb els quals abans només es podia somiar.

Els nous llenguatges de marques intenten anar una mica més enllà de la simple representació de dades que oferia HTML, i que eren ideals per a les persones, a nous sistemes que puguin fer que els programes puguin recuperar la informació que es troba en els ordinadors i processar-la de manera automàtica.

L'apartat "Introducció als llenguatges de marques. Classificació" mostra què són els llenguatges de marques, quines són les seves característiques, quina evolució han sofert i quins són els usos més importants.

L'apartat "Documents XML" entra en profunditat en el llenguatge XML i explica què són i com es poden crear documents XML, com es pot fer per comprovar que aquests documents són correctes, i s'hi veuen algunes eines per treballar amb documents XML.

Resultats d'aprenentatge

En acabar aquest mòdul, l'alumne:

1. **Reconeix les característiques de llenguatges de marques analitzant i interpretant fragments de codi.**
    - Identifica les característiques generals dels llenguatges de marques.
    - Reconeix els avantatges que proporcionen en el tractament de la informació.
    - Classifica els llenguatges de marques i identifica els més rellevants.
    - Diferencia els àmbits d'aplicació dels llenguatges de marques.
    - Reconeix la necessitat i els àmbits específics d'aplicació d'un llenguatge de marques de propòsit general.
    - Analitza les característiques pròpies del llenguatge XML.
    - Identifica l'estructura d'un document XML i les seves regles sintàctiques.
    - Contrasta la necessitat de crear documents XML ben formats i la influència pel que fa al processament.
    - Identifica els avantatges que aporten els espais de noms.

1. Introducció als llenguatges de marques. Classificació

Una definició poc estricta del que és un ordinador podria ser que "és una màquina electrònica que rep i processa dades per convertir-les en informació útil".

> Un dels components bàsics en un sistema informàtic són les dades que s'hi puguin introduir i com ho fa aquest sistema per emmagatzemar-les per usar-les posteriorment o mostrar-les de nou.

Per tant, una de les tasques bàsiques que fan els ordinadors és emmagatzemar la informació que els proporcionem per poder ser processada posteriorment. Aquesta informació pot ser de molts tipus diferents (text, imatges, vídeos, música...) però el realment important serà de quina manera l'emmagatzema l'ordinador per poder-la tractar posteriorment de manera eficient per generar més informació.

1.1 Les dades

Les dades són representacions d'aspectes del món real i se solen recollir per fer càlculs, mostrar-les, organitzar-les, etc., amb l'objectiu que posteriorment algú en pugui fer alguna cosa: prendre decisions, generar noves dades...

Si no s'és gaire estricte es podria dir que en un sistema informàtic qualsevol les úniques tasques que es desenvolupen consisteixen a emmagatzemar dades per processar-les per mitjà d'un programa que o bé aportarà algun tipus d'informació o bé es faran servir de nou per generar noves dades.

1.1.1 Característiques de les dades

Entre les característiques interessants sobre les dades en destaquen sobretot tres aspectes:

- A qui van dirigides
- La possibilitat de reutilitzar-les
- Que es puguin compartir

Destinatari de dades

Si s'intenta ser una mica més pràctic es veurà que realment les dades tindran una forma o una altra en funció del destinatari a qui vagin dirigides:

1. **Dades destinades als humans**: generalment les dades destinades al humans requeriran que tinguin alguna estructura concreta, amb uns formats determinats, amb textos decorats d'alguna manera. Hi apareixeran títols, caràcters en negreta, etc. Generalment no cal conèixer quin significat tenen les dades, ja que la interpretació es deixa al lector.

2. **Dades destinades als programes**: els programes generalment no necessiten que les dades tinguin informació sobre com s'han de representar, sinó que n'hi ha prou que siguin fàcilment identificables, que quedi clar de quin tipus són i que hi hagi alguna manera de determinar què signifiquen per poder-les tractar automàticament.

Reutilització de les dades

Molt sovint les dades es voldran reutilitzar per poder fer tasques diferents. Un error corrent sol ser emmagatzemar-les específicament per fer una tasca concreta, ja que això pot provocar que posteriorment sigui molt més complicat fer-les servir per fer altres tasques.

Per tant, és bàsic disposar d'un sistema d'emmagatzematge que permeti aconseguir que les dades puguin ser reutilitzades fàcilment i si pot ser que puguin ser reutilitzades tant per les persones com pels programes.

Compartició de les dades

En el passat, amb els ordinadors centrals la informació es generava i es processava en el mateix lloc. Però l'aparició dels ordinadors personals, l'eclosió de les xarxes i, sobretot, l'èxit d'Internet, ha creat tota una sèrie de problemàtiques que fins al moment no existien: les dades generades en un lloc ara poden ser consumides en un lloc totalment diferent, com ara:

- en sistemes operatius totalment diferents.

- en màquines que poden funcionar de maneres molt diverses.

Per tant, en un sistema informàtic modern s'ha de tenir en compte aquesta possibilitat a l'hora d'emmagatzemar dades. Hi ha la possibilitat que aquestes dades siguin compartides i, per tant, cal emmagatzemar-les d'alguna manera que no tingui problemes per usar-les en sistemes diferents.

1.2 Emmagatzematge de dades en ordinadors

Atesa la seva arquitectura, els ordinadors emmagatzemen la informació en binari i, per tant, tota la informació que s'hi pot emmagatzemar sempre es representarà en uns i zeros (1, 0). Això fa que per representar qualsevol tipus de dades (imatges, vídeos, text...) calgui fer algun tipus de procés que converteixi les dades a una representació en format binari.

Tradicionalment en els ordinadors les dades s'organitzen de dues maneres:

- Dades de text
- Dades binàries

1.2.1 Dades binàries

Emmagatzemar les dades de manera binària és la manera natural d'emmagatzemar dades en ordinadors. Estrictament parlant, les dades binàries estan en el format que fa servir l'ordinador, ja que només són una tira de bits un rere l'altre. Per tant, normalment, un ordinador no haurà fer cap procés especial per emmagatzemar i llegir dades binàries.

Les dades en format binari tenen una sèrie de característiques que les fan ideals per als ordinadors:

- Generalment estan optimitzades per ocupar l'espai necessari.
- Els ordinadors les llegeixen fàcilment.
- Poden tenir estructura.
- És relativament fàcil afegir-hi metadades.

Si un programa vol usar les dades binàries normalment només necessitarà conèixer la mida en bits i, sobretot, conèixer **de quina manera s'hi ha emmagatzemat** la informació.

Per emmagatzemar el nombre 150 només cal convertir aquest valor decimal a la seva representació en binari i emmagatzemar-lo. És trivial comprovar que pot ser emmagatzemat en un sol byte (8 bits) com es pot veure a la taula 1.1.

Taula 1.1. Representació del nombre 150 en binari

valor decimal	valor binari
150	10010110

Un avantatge afegit de la representació de nombres en binari és que ja estan disponibles immediatament per fer càlculs numèrics, ja que realment es tracta de nombres. No caldrà fer cap transformació per poder usar aquest nombre en qualsevol càlcul.

Metadades

Molt sovint no s'emmagatzemen directament les dades tal com estan sinó que es processen per optimitzar-les, com ara emmagatzemant informació sobre el seu contingut o aplicant-hi procediments d'optimització. Aquestes optimitzacions són transparents per l'usuari final, que visualitzarà les dades normalment.

Una de les maneres més senzilles de representar una imatge en un ordinador consisteix a representar cada un dels punts de color que la formen. O sigui, que només cal dir de quin color serà cada un dels punts per poder emmagatzemar la imatge en un fitxer (figura 1.1).

Figura 1.1. Representació d'un gràfic en un ordinador

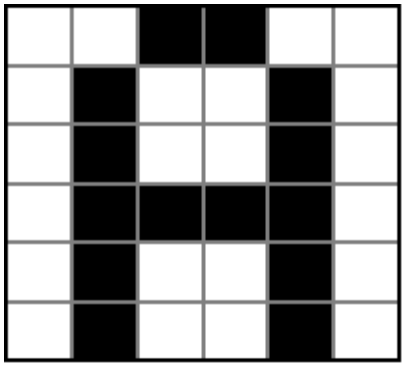

Podem fer servir un mètode senzill per representar la imatge anterior, com podria ser definir si cada un dels punts és de color blanc (0) o negre (1). La imatge podrà ser representada d'aquesta manera:

```
001100
010010
010010
011110
010010
010010
```

En realitat un ordinador no emmagatzemarà la informació d'aquesta manera sinó de manera lineal, ignorant els salts de línia. Una representació més propera a com ho faria realment un ordinador seria aquesta:

```
001100010010010010011110010010010010
```

Representar la informació d'aquesta manera fa que les imatges ocupin molt d'espai i per aquest motiu normalment es fan servir mètodes per optimitzar-ne l'emmagatzematge.

Una de les maneres d'optimitzar l'espai ocupat per la imatge podria ser adonar-se'n que hi han diverses repeticions dels colors. De manera que es podria intentar aprofitar aquesta característica per aconseguir un fitxer binari més petit.

Es podria fer que en comptes d'especificar els punts un per un si hi ha una repetició es pogués especificar el nombre de vegades que es repeteix el color. D'aquesta manera un punt blanc aïllat es representarà normalment, però si es troben quatre punts blancs, en comptes d'emmagatzemar `0000` es pot representar amb `40` (4 blancs)

El resultat d'aplicar aquest procediment a la mateixa imatge ens donarà:

```
1 2021301201201201204120120120 10
```

Aquest procediment té l'avantatge afegit que amb el nou sistema les dades ocupen un 10% menys d'espai (33 caràcters) que abans (36 caràcters).

A pesar que amb el nou sistema no s'emmagatzemen tots els punts un programa pot aconseguir fàcilment representar-los en pantalla seguint les especificacions.

Es pot veure que en la representació binària hi ha tota una sèrie de valors que estrictament no són dades de la imatge (els nombres 2, 3 i 4) sinó que són dades que fan referència a la manera com s'han emmagatzemat les dades. Aquestes dades s'anomenen "**metadades**"

> Les metadades són dades sobre les dades.

L'ús de metadades optimitza l'emmagatzematge d'informació però alhora fa que la compartició de la informació continguda en el fitxer sigui molt més complexa. Però això sí, cal que el programa que vulgui recuperar la informació *conegui el procediment que s'ha fet servir* o no obtindrà les dades correctes.

Dades estructurades

Les dades en la manera com les generem els humans no estan en un format que en faciliti el tractament automàtic per part d'un ordinador. Per aquest motiu sovint les dades que han de ser processades pels ordinadors es converteixen a algun format que sigui més idoni per al tractament. El més corrent és tractar les dades per tal que tinguin algun tipus d'estructura.

> Els tipus de dades estructurats són agrupacions d'altres tipus de dades (normalment tipus més senzills).

La manera més corrent d'estructurar dades binàries sol ser tenir-les agrupades en registres que contenen la informació repetitiva d'una dada en concret. És habitual que els llenguatges de programació tinguin alguna manera de definir dades estructurades. Per exemple, per a aquestes tasques el llenguatge C fa servir els `struct`.

```c
struct alumne {
    char nom[10];
    char cognom[10];
    int nota;
}
```

Si es pot accedir a cada un dels registres del fitxer es pot accedir de cop a les dades d'un alumne, es pot identificar ràpidament la part de les dades que és el nom, cognom o nota, i a més sabem si les dades han de ser interpretades com a nombres o com a text.

En l'exemple de la figura 1.2 podeu veure que es pot identificar a quina dada correspòn cada un dels caràcters. Els deu primers són el nom, els 10 següents són el cognom i els quatre següents són el número enter (32 bits).

FIGURA 1.2. Representació de dades en una estructura fent servir caràcters

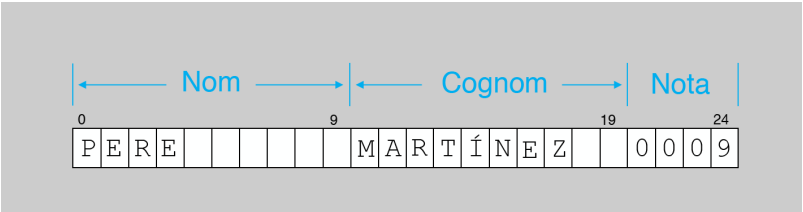

Generalment aquestes dades estructurades s'emmagatzemen en forma de llistes o conjunts de registres, de manera que el desenvolupador del programa podrà accedir a les dades de tots els `alumnes` simplement recorrent els diferents registres un per un.

Les dades estructurades facilitaran que les aplicacions les puguin tractar de manera automàtica.

Problemes

Les dades binàries també tenen problemes associats a l'hora de ser compartides, ja que en el món modern les dades s'han de compartir en màquines en què no han estat generades, que poden tenir sistemes operatius diferents, poden ser màquines totalment diferents, etc. Les dades binàries optimitzades per al sistema en què es generen no sempre seran ben enteses pels altres sistemes.

Estructura de les dades

Un dels problemes de donar estructura a les dades és que aquesta estructura només l'entendran els programes que tinguin informació sobre l'estructura. En definir quines són les dades que farà servir el programa es defineix quina mida tindrà cada camp i de quina manera es desaran les dades dins del fitxer binari.

Si agafem l'exemple que hem vist en la figura 1.1, perquè un programa pugui representar la imatge de manera correcta cal que tingui prou informació per fer-ho:

- Primer cal que conegui que el que hi ha representat és una imatge.
- També ha de saber que es desa cada punt de color amb un sol caràcter.
- És bàsic que conegui l'equivalència de colors que hem fet: 0 és blanc, 1 és negre.
- I necessita saber que la imatge és de 6 caràcters de llargada per 6 caràcters d'amplada o el resultat serà molt diferent del que era inicialment (figura 1.3)
- Si s'ha representat la imatge fent servir el sistema optimitzat cal que conegui que els valors numèrics superiors a 1 indiquen que aquest valor no és un color sinó que són el nombre de repeticions del color següent.

Figura 1.3. Intents de representar el gràfic sense conèixer-ne les dimensions

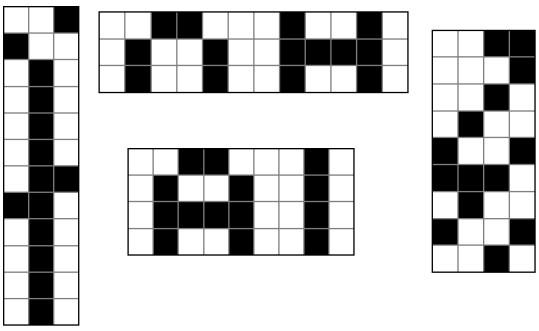

Totes aquestes coses són les que cal conèixer per poder usar les dades d'un exemple senzill; per tant, podeu imaginar-vos què passaria amb un exemple més complex.

Forma de lectura del processador

De la mateixa manera que en els llenguatges humans hi ha idiomes que s'escriuen d'esquerra a dreta i d'altres de dreta a esquerra, tots els processadors no emmagatzemen la informació de la mateixa manera (tècnicament es fa referència a l'ordre de lectura en les adreces de memòria).

Hi ha dos grans sistemes per emmagatzemar la informació en ordinadors:

- **Big endian**: les dades s'escriuen en l'ordre en què es creen. Així, per escriure `hola` en l'ordinador s'emmagatzemaria `h`, `o`, `l`, `a`. Aquest sistema és el que fan servir els processadors de Motorola.
- **Little endian**: les dades es desen de menys rellevant a més rellevant: `a`, `l`, `o`, `h`. Aquest sistema és el que fan servir els processadors d'Intel.

El més habitual és que els ordinadors només facin servir un dels dos sistemes, tot i que n'hi ha que poden funcionar amb tots dos indistintament (ARM, PowerPC, PA-RISC...).

Això no és important quan les dades es passen entre ordinadors que funcionen amb el mateix tipus, però és un aspecte vital que cal tenir en compte si els ordinadors

que es passen la informació són de tipus diferents, ja que les dades binàries passades d'un sistema a l'altre poden ser totalment malinterpretades per culpa que s'emmagatzemen internament de manera diferent.

Lectura per humans

Un problema diferent és que les dades en format binari estan pensades per ser llegides per màquines (figura 1.4) però no per humans, de manera que són ideals per ser emmagatzemades en màquines, van bé per a la comunicació d'informació entre màquines, però en canvi perquè un humà les pugui fer servir **caldrà tenir un programa específic** per llegir-les.

Figura 1.4. El format binari no està pensat per ser llegit per humans

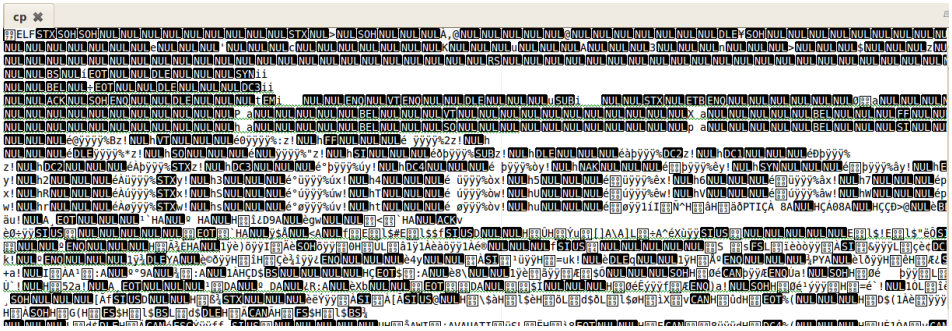

Formats binaris estàndards

S'han definit alguns estàndards de fitxers binaris, cosa que permet que qualsevol pugui fer programes que puguin interpretar aquests fitxers.

Això és el que passa per exemple, amb els fitxers d'imatges JPG, PNG, GIF..., que poden ser llegits per diferents programes perquè la seva especificació és pública.

- JPG - Estàndard ISO/IEC 10918
- GIF - Especificació del W3C gif89a
- PNG - Estàndard ISO/IEC 15948

I a més, no serveix qualsevol programa, sinó que cal que el programa entengui l'estructura de les dades que conté el fitxer. Per exemple, les dades generades pel Microsoft Word no poden ser obertes amb el programa de dibuix Gimp perquè no està preparat per entendre-les.

Si qui ha desenvolupat el programa no ha fet pública de quina manera es desen les dades binàries que es generen serà molt difícil compartir dades amb altres usuaris si no disposen del mateix programa.

1.2.2 Dades de text

Per solucionar el problema que calgui recórrer a programes específics per recuperar les dades que hi ha en un fitxer una possibilitat és fer el més obvi, fer el mateix que han fet els humans durant segles. Els humans en escriure ja estan fent servir una codificació i, per tant, si es fa servir la mateixa codificació tindrem les dades en un format fàcil de fer servir i entendre que no tindrà problemes per ser llegit pels programes.

En fitxers binaris el component d'informació més petit era el bit, en fitxers de text el component més petit és el caràcter.

Els fitxers de text emmagatzemen la informació lletra per lletra d'una manera similar a com ho faria un humà en escriure. Això fa que s'estigui generant una informació que es podrà llegir de la mateixa manera que es llegeix un document de paper.

Per a un ordinador no hi ha gaire diferència a l'hora d'emmagatzemar els fitxers

de text o els fitxers binaris, ja que els fitxers de text també són tires de bits. La diferència és que aquest cop els bits estan agrupats d'una manera estàndard i coneguda: un **codi de caràcters**.

Codis de caràcters

Representar les dades en un ordinador en forma de text implica que per poder representar una paraula qualsevol a l'ordinador prèviament haurà de ser *codificada* per fer que pugui ser representada en binari (recordem que els ordinadors només poden representar dades en binari). Aquesta codificació sol consistir a determinar una quantitat de bits predefinida per marcar un caràcter i posteriorment s'associa un valor numèric a cada un dels caràcters.

Observeu que per a un ordinador l'espai en blanc és un caràcter més.

L'equivalència entre els caràcters i els seus valors numèrics no es pot fer de manera aleatòria, ja que s'estaria creant el mateix problema que hi ha amb les dades binàries. Si es vol aconseguir que les dades es puguin llegir en diferents sistemes cal seguir algun tipus de norma coneguda per tothom. Per aquest motiu van aparèixer els **estàndards de codificació de caràcters**.

Problema de la codificació de caràcters

Per exemple, si tinguéssim un idioma que només tingués 5 caràcters (les vocals *AEIOU*) es podrien codificar tots els caràcters d'aquest idioma fent servir només 3 bits. Per tant, una possible codificació de les lletres de l'idioma podria ser la de la taula 1.2.

Taula 1.2. Possible codificació de lletres

Caràcter	Valor decimal	Valor binari
A	0	000
E	1	001
I	2	010
O	3	011
U	4	100
Espai	5	101

Això ens permetria codificar la frase "AI AI AI" d'aquesta manera:

```
1 000010101000010101000010
```

Però davant del mateix problema una altra persona podria triar una combinació diferent, com la de la taula 1.3.

Taula 1.3. Alternativa diferent de codificació

Caràcter	Valor decimal	Valor binari
Espai	0	000
A	1	001
E	2	010
I	3	011
O	4	100
U	5	101

Això provocaria que en comunicar la frase "AI AI AI" generada amb el primer sistema, en el

segon es descodificaria:

```
000  --> Espai
010  --> E
101  --> U
```

I interpretaria que el missatge és " EU EU EU".

El procediment de tenir una taula amb els valors numèrics associats i simplement fer la conversió és el procediment més habitual però també es donen casos en què la codificació hagi de complir algun tipus de regles o restriccions a l'hora de fer la conversió.

ASCII

Un dels primers estàndards que va ser adoptat majoritàriament va ser ASCII (*American standard code for information interchange*), que es pot veure a la taula 1.4. ASCII codifica cada un dels caràcters amb set bits i defineix a quin valor numèric es correspon cada un dels caràcters de la llengua anglesa.

Taula 1.4. Caràcters imprimibles de l'ASCII

Caràcter	Valor decimal	Caràcter	Valor decimal	Caràcter	Valor decimal	Caràcter	Valor decimal	Caràcter	Valor decimal
	32	3	51	F	70	Y	89	l	108
!	33	4	52	G	71	Z	90	m	109
"	34	5	53	H	72	[	91	n	110
#	35	6	54	I	73	\	92	o	111
$	36	7	55	J	74	]	93	p	112
%	37	8	56	K	75	^	94	q	113
&	38	9	57	L	76	_	95	r	114
'	39	:	58	M	77	`	96	s	115
(	40	;	59	N	78	a	97	t	116
)	41	<	60	O	79	b	98	u	117
*	42	=	61	P	80	c	99	v	118
+	43	>	62	Q	81	d	100	w	119
,	44	?	63	R	82	e	101	x	120
-	45	@	64	S	83	f	102	y	121
.	46	A	65	T	84	g	103	z	122
/	47	B	66	U	85	h	104	{	123
0	48	C	67	V	86	i	105	|	124
1	49	D	68	W	87	j	106	}	125
2	50	E	69	X	88	k	107	~	126

La codificació que es fa en ASCII és relativament senzilla: simplement es compara cada un dels caràcters del text per codificar en la taula i se n'obté el valor numèric en binari. Per exemple, per codificar la paraula *Hola* en un ordinador que estigui funcionant amb el codi ASCII haurem de convertir cada un dels caràcters en el seu equivalent numèric (taula 1.5).

Taula 1.5. Conversió de caràcters a binari fent servir ASCII

Caràcter	decimal	binari
H	72	1001000
o	111	1101111
l	108	1101100
a	97	1100001

El primer problema que es va trobar per a l'ASCII era que només estava pensat per l'anglès i, per tant, no es disposava de caràcters d'ús corrent en altres llengües: ç, à, á, ñ, etc. Per tant, per poder expandir-se a altres zones es va crear un *ASCII expandit*, que va incrementar el nombre de de bits a 8, i gràcies a aquest bit extra s'hi podien especificar els caràcters específics de cada idioma que l'anglès no tenia. D'aquesta manera es permetia crear textos en altres idiomes que fessin servir l'alfabet llatí.

Això va fer que apareguessin moltes varietats d'ASCII, especialitzades en un grup d'idiomes (ISO 8859-1, ISO 8859-2, etc.).

Però com que cada idioma feia servir els valors nous per afegir els seus caràcters propis la informació representada fent servir un d'aquests "ASCII" no sempre es veia bé en un altre dels "ASCII".

A més, ASCII i ASCII expandit només estaven pensats per a idiomes que fessin servir l'alfabet llatí i, per tant, els idiomes no basats en l'alfabet llatí havien de recórrer a altres codificacions.

Unicode

Unicode és un intent de substituir els codis de caràcters existents per un de genèric que serveixi per a totes les llengües, i per tant superi tots els problemes d'incompatibilitat que es produïen en entorns multilingües i permeti afegir els caràcters no llatins.

La idea bàsica de Unicode és donar a cada un dels símbols un identificador únic universal de manera que es puguin fer servir en el mateix document idiomes diferents sense que això comporti problemes de representació.

L'adopció de Unicode resol d'una vegada tots els problemes de representació de caràcters en fitxers de text.

Malgrat els seus avantatges, Unicode també va rebre crítiques de la comunitat anglòfona, perquè feia que els textos acabessin ocupant més del doble que en ASCII.

Unicode defineix tres formes de codificació bàsiques UTF (*Unicode transformation format*), que podeu veure a la taula 1.6.

Taula 1.6. Formes de codificació de Unicode

Nom	
UTF-8	Sistema basat en un byte amb alguns símbols de longitud variable
UTF-16	Sistema de longitud variable basada en dos bytes
UTF-32	Sistema de longitud fixa que fa servir 32 bits per cada caràcter

Unicode ha estat adoptat de manera general per la majoria de sistemes operatius moderns. Actualment gairebé tots els sistemes operatius fan servir alguna varietat de Unicode (el Linux sol fer servir UTF-8 i el Windows adapta UTF-16).

Compartició d'informació

Gràcies a l'ús d'estàndards de codis de caràcters la informació en forma de text és més fàcilment compartida que no pas la informació binària, ja que els codis de caràcters que fan servir els sistemes per representar el text són coneguts i poden ser implementats lliurement.

Per tant, emmagatzemar les dades en format de text aporta dos grans avantatges:

- Les poden usar una gran quantitat de programes que ja existeixen (editors de text, navegadors, etc.).
- Poden llegides per humans.

Amb un dels programes més simples que hi ha, un editor de text, es pot crear un document que es podrà compartir amb qualsevol persona que entengui l'idioma en què ha estat escrit. I com que tots els sistemes operatius porten de sèrie programes capaços de carregar fitxers, si s'envia el fitxer a algú aquest no tindrà cap problema per interpretar les dades quan les rebi.

Problemes

Generar informació en fitxers de text també té alguns problemes:

- Ocupen més espai al disc que els binaris.
- Hi ha múltiples codis de caràcters diferents.
- La manera com els tracten els diferents sistemes operatius.
- Falta d'estructuració de les dades.

Però a pesar dels problemes, aquests són molt menys importants que els que tenim per compartir fitxers binaris. Per tant **els fitxers de text són la manera més senzilla d'assegurar-nos que podem compartir la informació que hi ha amb altres persones**.

Espai al disc

Un dels problemes que tenen els fitxers de text és que la informació ocupa molt més espai del que ocuparia si s'emmagatzemés en format binari. Com podem veure en la taula (taula 1.7), si volem emmagatzemar el nombre 150 en un ordinador el resultat serà diferent en funció del format triat.

Taula 1.7. Diferència entre emmagatzemar en format de text i binari

Format	Representació interna
Format binari	10010110
Format textual	00110001 00110101 00110000

Per emmagatzemar el nombre en format binari simplement es converteix a binari i es podrà emmagatzemar en un byte (8 bits) mentre que si es vol emmagatzemar en format de text fent servir ISO-8869-1 s'hauran de desar per separat cada un del tres caràcters (`1`, `5` i `0`). Amb el segon sistema caldran 3 bytes (24 bits): el triple d'espai!

Però a més, si la informació desada en format binari cal per fer algun càlcul, ja es pot fer servir immediatament, ja que s'emmagatzema realment el nombre; mentre que si tenim el nombre en format de text l'haurem de convertir al seu equivalent numèric abans de poder fer qualsevol operació matemàtica.

Múltiples codis de caràcters

Tot i que Unicode intenta que aquest problema desaparegui, alguns sistemes operatius encara fan servir múltiples codis de caràcters i els usuaris tenen informació antiga desada en codis de caràcters antics. Per tant, la compartició de dades encara provoca problemes que poden ser des de la simple representació incorrecta d'algun caràcter fins a corrompre el text o fer que la lectura de la informació sigui impossible.

Figura 1.5. Problema de codificació incorrecta de caràcters

QuÃ¨ Ã©s l'IOC?

dijous, 10 de febrer de 2011 09:29

La raÃ³ de ser de l'Institut Obert de Catalunya es troba plenament vinculada als objectius del Departament d'Ensenyament

En primer lloc, l'extensiÃ³ de l'educaciÃ³, facilitant que pugui arribar al mÃ xim de persones superant les limitacions de l'espai i del temps.

En segon lloc, una educaciÃ³ que ha de posar els interessos, les necessitats i les possibilitats de progrÃ©s de les persones en el centre d'un model educatiu flexible i adaptable.

En tercer lloc, una proposta educativa que, en colÂ·laboraciÃ³ amb les altres, impulsa la formaciÃ³ al llarg de la vida.

I, finalment, el treball compartit per presentar una oferta educativa de qualitat i amb voluntat de millora, que vagi incorporant les innovacions en les tecnologies de la informaciÃ³ i de la comunicaciÃ³ amb l'objectiu de donar un millor servei educatiu.

Si l'objectiu és fer que les dades es puguin reutilitzar tant per programes com per persones, els caràcters erronis s'han d'evitar. Com es veu en la figura 1.5 els problemes en alguns casos poden ser poc importants si es vol que una persona entengui el que hi posa, però poden ser un problema molt gran per a un programa, ja que la seva capacitat d'interpretació és molt inferior.

L'adopció de Unicode en la majoria de sistemes operatius està fent que aquest problema s'estigui reduint i el fet que la quantitat de codificacions de caràcters sigui molt inferior a la quantitat de codis binaris fa que **les dades en format de text es considerin fàcilment compartibles**.

Si algú hagués emmagatzemat informació durant els anys setanta, i encara es tingués la capacitat de llegir el suport en el qual es van desar, difícilment es podria recuperar alguna cosa de les dades binàries que s'hi trobessin, ja que els programes que les van generar ja no existeixen o no funcionen amb els sistemes operatius moderns, i en canvi és possible que les dades emmagatzemades en format de text sí que es poguessin recuperar.

Representació de caràcters no textuals

Un altre problema que hi sol haver en la lectura de dades de text quan es fa en diferents sistemes operatius sol estar relacionada amb com es fa el tractament dels caràcters no textuals.

L'exemple més conegut és el diferent tractament que fan dels salts de línia els sistemes Windows i les diferents varietats de Unix i Linux. Per representar els salts de línia en el text els sistemes operatius fan servir algun dels caràcters no imprimibles del codi de caràcters, i per tant, d'aquesta manera tenen una manera "transparent a l'usuari" de poder representar el text tal com l'ha escrit.

El problema és que dos dels sistemes operatius més populars, Windows i Unix, ho fan de manera diferent. Mentre que Unix fa servir un sol caràcter per indicar el salt de línia, LF (*line feed*), Windows en fa servir dos: CR (*carriage Return*) i LF (*line feed*). El resultat és que en obrir un fitxer generat en un sistema Unix en un sistema en Windows els salts de línia han desaparegut i en el seu lloc hi apareix un rectangle que representa el caràcter LF (figura 1.6).

Figura 1.6. Diferència del tractament en els salts de línia entre Windows i Linux

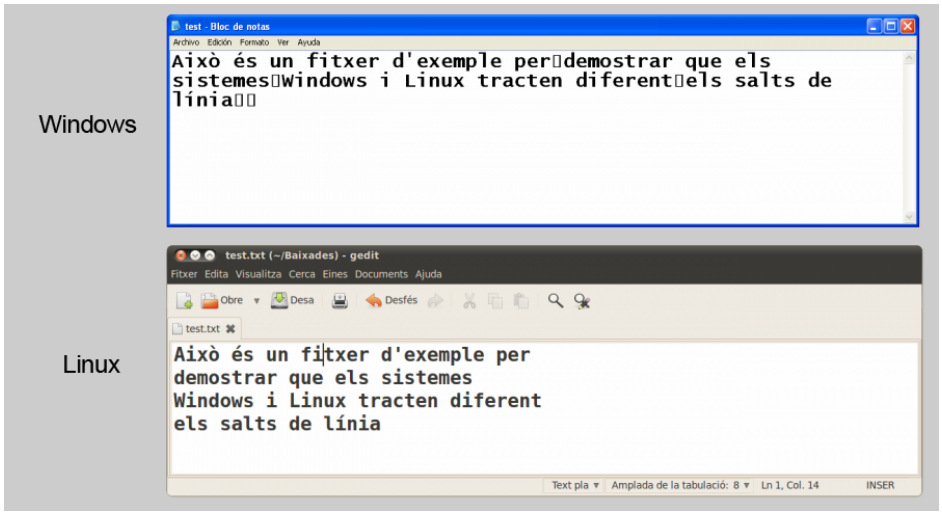

Actualment molt programes ja detecten aquest problema i el compensen automàticament de manera transparent a l'usuari.

Lectura de dades automatitzada

Els programes d'ordinador encara no són gaire bons interpretant les dades si són en text narratiu i, per tant, generalment convé que les dades que hauran de ser tractades per programes d'ordinador estiguin definides amb algun tipus d'**estructura** per tal que els siguin més fàcils de tractar.

S'han inventat sistemes per fer que les dades dels fitxers de text puguin ser estructurades. Un dels formats que s'ha fet servir durant molt de temps per exportar dades estructurades contingudes en bases de dades o fulls de càlcul a text ha estat el CSV (*comma separated values*).

El CSV simplement es limita a separar cada un dels registres de l'estructura en línies i els camps se separen amb comes. A més, per poder definir els tipus de dades, envolta de cometes les dades de text, mentre que no es posen cometes en les numèriques.

```
"Manel", "Puig", "Garcia", 8
"Pere", "González", "Puigdevall", 5
"Maria", "Pous", "Canadell", 7
```

> CSV és una manera senzilla de desar dades estructurades en format de text que permet a un programa identificar les diferents dades que conté cada registre i a més interpretar de quin tipus són.

A més, un avantatge afegit de CSV és que és relativament fàcil afegir més dades a un fitxer que estigui en format CSV, ja que només cal un editor de text i respectar les regles de separar les dades amb comes i fer un salt de línia per cada registre.

Per tant un programa pot deduir fàcilment a partir de l'exemple anterior que les dades són com es veu en la taula 1.8.

Taula 1.8. Interpretació del significat del fitxer CSV

Dada	Resultat
Manel	Dada de text perquè està entre cometes
Puig	Dada de text perquè està entre cometes
Garcia	Dada de text perquè està entre cometes
8	Dada numèrica

Però els sistemes d'estructurar dades en fitxers de text també tenen problemes. Si necessitem afegir més dades a cada registre és gairebé segur que obligarà a fer canvis en el programa que les tractarà. El programa necessita saber quines dades hi ha en cada una de les columnes per poder treballar i, per tant, si modifiquem les columnes pot malinterpretar les dades.

Problema d'afegir dades en un CSV

Per exemple, si afegim una dada nova amb tractament de la persona al davant del fitxer anterior:

```
"Sr", "Manel", "Puig", "Garcia", 8
"Sr", "Pere", "González", "Puigdevall", 5
"Sra", "Maria", "Pous", "Canadell", 7
```

Si es fa servir el mateix programa que abans, aquest pot pensar que els noms de les persones són "Sr" i "Sra" i que les notes són "Garcia", "Puigdevall", etc.

Però afegir dades no és l'únic problema que tenim, ja que representar les dades d'aquesta manera n'arruïna la lectura de la gent que no faci servir els programes específics. Qui pot saber que el nombre és una nota i no una altra cosa?

A qualsevol de vosaltres se us pot acudir una manera senzilla d'evitar aquest problema, que consisteix a fer que la primera columna indiqui què és cada una de les dades que s'hi representen a continuació.

```
"nom", "cognom", "cognom2", "nota"
"Manel", "Puig", "Garcia", 8
"Pere", "González", "Puigdevall", 5
"Maria", "Pous", "Canadell", 7
```

Desenvolupar un programa que interpreti aquestes dades i que s'asseguri que no es produeixen errors és bastant complex.

1.3 Fitxers de marques

Es pot dir que els fitxers de marques són una manera diferent d'emmagatzemar informació en ordinadors que s'afegeix a les maneres d'emmagatzemar la informació per mitjà de fitxers binaris o fitxers de text. L'objectiu principal dels fitxers de marques és intentar **recollir les millors característiques dels fitxers de text i binaris** i esquivar-ne els problemes.

Els fitxers de marques prenen com a base els fitxers de text per aprofitar-se de les característiques més interessants d'aquest tipus de fitxers:

- La facilitat de creació i lectura.
- El compliment d'estàndards d'emmagatzematge definits i públics.

Com que els fitxers de text sempre estan emmagatzemats en algun codi de caràcters conegut (ASCII, UTF-8, etc.) s'aconsegueix que puguin ser transportats i llegits en qualsevol plataforma, sistema operatiu o programa que pugui interpretar aquests codis de caràcters. Per tant, els llenguatges de marques s'aprofitaran d'aquesta característica, en estar basats en el format de text.

A més, de retruc, també tindran l'avantatge que podran ser oberts i creats amb els programes d'edició de text estàndard. Des d'editors tan simples com el Bloc de notes dels sistemes Windows o el Gedit de sistemes Unix fins a editors més complexos com el Microsoft Word, passant per editors especialitzats en XML com l'Oxygen XML Editor.

Els fitxers de marques, per tant, s'aprofiten d'un dels grans avantatges dels arxius de text sobre els arxius binaris, ja que aquests darrers requereixen ser oberts amb un programa específic que en pugui interpretar el format.

Però els fitxers de marques no solament s'intenten aprofitar de les característiques dels fitxers de text sinó que també intenten **aconseguir les característiques més interessants dels fitxers binaris**, com:

- La incorporació de metadades.
- La definició de l'estructura de les dades.

Això fa que els llenguatges de marques adquireixin una de les característiques més interessants dels fitxers binaris, que és la possibilitat d'incorporar informació sobre les dades –metadades– però intentant que afecti el mínim possible la llegibilitat del document.

També permeten definir les dades i la seva estructura de manera que sigui senzill per un programa poder-les interpretar.

Gràcies als avantatges que ofereixen els llenguatges de marques, aquests s'han convertit ràpidament en una de les maneres habituals de representar dades i es poden trobar contínuament en les tasques habituals amb ordinadors:

- L'exponent més popular és Internet –el Web–, que està basat totalment en els llenguatges de marques.
- Molts dels programes d'ordinador que feu servir habitualment fan servir en algun moment alguna o altra forma d'algun llenguatge de marques per a emmagatzemar les seves dades de configuració o de resultats:
  - Internament els formats de documents de Microsoft Office o d'OpenOffice.org o LibreOffice estan basats en llenguatges de marques.
  - Microsoft Visual Studio desa la seva configuració fent servir llenguatges de marques.
  - etc.

1.3.1 Les marques

Les marques són una sèrie de codis que s'incorporen als documents electrònics per determinar-ne el format, la manera com s'han d'imprimir, l'estructura de les dades, etc. Per tant, són **anotacions que s'incorporen a les dades però que no en formen part**.

Les marques, per tant, han de ser fàcilment distingibles del text normal (per la seva posició, perquè segueixen algun tipus de sintaxi, etc.). Les marques més usades són les que estan formades per textos descriptius i estan envoltades dels símbols

de "més petit" (<) i "més gran" (>) i normalment n'hi sol haver una al principi i una al final:

```
<nom>Manel Puig Garcia</nom>
```

Aquestes marques poden ser imbricades per **indicar estructures de dades**:

```
<persona>
   <nom>Manel Puig Garcia</nom>
   <nom>Pere González Puigdevall</nom>
   <nom>Maria Pous Canadell</nom>
</persona>
```

Però hi ha moltes altres formes de marques. Una altra idea consisteix a trobar alguna combinació de caràcters que surti rarament en el llenguatge habitual. El TeX fa servir les barres invertides per a indicar l'inici de les marques

```
\section{Persones}
\begin{itemize}
\item Manel Puig Garcia
\item Pere González Puigdevall
\item Maria Pous Canadell
\end{itemize}
```

Altres llenguatges de marques fan servir caràcters no habituals en determinades posicions per indicar que són marques. Per exemple amb Wiki Markup els caràcters "=" a la primera posició d'una línia es fan servir per indicar que el text és un títol d'apartat i el $*$ per les llistes de punts:

```
= Persones =
* Manel Puig Garcia
* Pere González Puigdevall
* Maria Pous Canadell
```

La idea general és que cal que les marques siguin fàcilment identificables per poder-nos aprofitar dels avantatges que ofereixen els llenguatges de marques.

1.3.2 Característiques dels llenguatges de marques

> Els llenguatges de marques són una manera de codificar un document de text de manera que per mitjà de les marques (l'equivalent de les metadades dels fitxers binaris) s'hi incorpora informació relativa a com s'ha de representar el text, sobre quina estructura tenen les dades que conté, etc.

Els llenguatges de marques han destacat per una sèrie de característiques que els han convertit en els tipus de llenguatges més usats en la informàtica actual per emmagatzemar i representar les dades. Entre les característiques més interessants que ofereixen els llenguatges de marques hi ha:

- Que es basen en el text pla.

- Que permeten fer servir metadades.
- Que són fàcils d'interpretar i processar.
- Que són fàcils de crear i prou flexibles per representar dades molt diverses.

Les aplicacions d'Internet i molts dels programes d'ordinador que es fan servir habitualment fan servir d'alguna manera o altra algun llenguatge de marques.

Basats en text pla

Els llenguatges de marques es basen en text pla sense format. Aquests caràcters poden estar codificats en diferents codis de caràcters: ASCII, ISO-8859-1, UTF-8, etc.

Un dels avantatges que intenten aportar els llenguatges de marques és que es poden interpretar directament i això només és possible si fem servir el format de text, ja que els binaris requereixen un programa per interpretar-los. Però a més tenen l'avantatge que són independents de la plataforma, del sistema operatiu o del programa.

El fet que estiguin basats en format de text fa que siguin fàcils de crear i de modificar perquè només requereixen un simple editor de textos.

Ús de metadades

Les marques s'intercalen entre el contingut del document, de manera que generalment aquestes etiquetes solen ser descriptives de què és el que indica el contingut de les dades que contenen.

Aquestes marques són la manera com s'afegeixen les metadades als documents de text i com s'aconsegueixen superar les limitacions del format de text i aconseguir alguns dels avantatges dels fitxers binaris.

Facilitat de procés

Els llenguatges de marques permeten que el processament de les dades que continguin pugui ser automatitzat d'alguna manera, ja que el fitxer conté l'estructura de les dades que conté.

El fet d'incloure l'estructura permetrà que un programa pugui interpretar cada una de les dades d'un fitxer de marques per representar-lo o tractar-lo convenientment, ja que mostren l'estructura de les dades que contenen.

Posteriorment un programa podrà interpretar gràcies a les marques què és el que significa cada una de les dades del document.

Facilitat de creació i representació de dades diverses

A pesar que van ser pensats per contenir dades de text, els llenguatges de marques han demostrat que són capaços de contenir dades de molts tipus diferents.

Actualment s'estan fent servir fitxers de marques per representar imatges vectorials, fórmules matemàtiques, crear pàgines web, executar funcions remotes per mitjà de serveis web, representar música o sons, etc.

I sense importar quin tipus de dades s'hi representin sempre hi haurà la possibilitat de crear aquests fitxers des d'un editor de text bàsic.

1.3.3 Classificació dels llenguatges de marques

És complicat fer una classificació dels llenguatges de marques que hi ha però generalment s'accepta que en tenim dos grans grups basant-nos en quin és l'**objectiu bàsic** del llenguatge de marques:

- **Llenguatges procedimentals i de presentació**, orientats a especificar com s'ha de representar la informació.
- **Llenguatges descriptius o semàntics**: orientats a descriure l'estructura de les dades que conté.

Aquesta és la classificació més acceptada però, com molt sovint passa en l'àmbit de la Informàtica, ens podem trobar llenguatges que tinguin aspectes dels dos grups i permetin tant definir la manera de presentar la informació com definir-ne l'estructura.

Procedimentals i de presentació

En aquests llenguatges el que es fa és indicar de quina manera s'ha de fer la presentació de les dades. Ja sigui per mitjà d'informació per al disseny (marcar negretes, títols, etc.) o de procediments que ha de fer el programari de representació. L'exemple més popular d'aquests llenguatges és l'HTML però n'hi ha molts més: TeX, Wikitext...

En aquests casos els documents ens poden servir per determinar de quina manera es mostrarà el document a qui el llegeixi.

Si agafem un exemple senzill fent servir el llenguatge de marques lleuger *Wiki markup*, que fa servir Mediawiki (programa amb el qual s'ha desenvolupat la Wikipedia):

```
= Classe =

== Assignatura: XML ==
[[Fitxer:xml.png]]
```

```
'''Professor''':
:* ''Manel Puig''

'''Alumnes'''

:* Frederic Puig
:* Filomeno Garcia
:* Manel Puigdevall
```

Que ens mostrarà el que es veu a la figura 1.7:

Figura 1.7. Representació del text en format //wikicode//

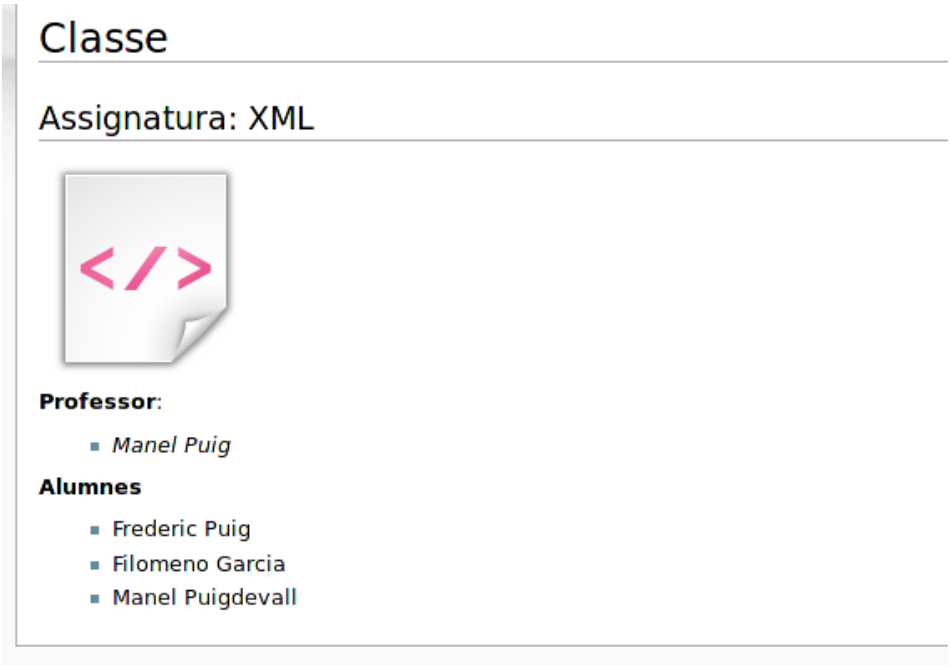

Es pot veure com el programa ha interpretat les marques "=" o "==" per mostrar els diferents nivells dels títols, que els símbols ":*" indiquen llistes de punts i que amb la diferent quantitat de cometes s'indiquen negretes o cursiva. Per tant, és un exemple que indica clarament **com ha de ser representada la informació**.

Descriptius o semàntics

En aquests llenguatges es descriu quina estructura lògica té el document ignorant de quina manera serà representada en els programes. Només es posen les marques amb l'objectiu de definir les parts que donen estructura al document. L'exemple més important és l'XML però n'hi algun altre que està tenint molt de suport, com per exemple JSON.

En el document següent tenim un exemple d'un fitxer de marques que dóna informació sobre persones:

```
<alumnes>
    <persona>
        <nom>Pere</nom>
        <cognom>Puig</cognom>
    </persona>
```

```
    <persona>
        <nom>Manel</nom>
        <cognom>Garcia</cognom>
    </persona>
</alumnes>
```

Es pot veure clarament que la informació de les marques en el document estableix quin és el contingut de les dades: una llista d'alumnes. Amb un simple cop d'ull resulta fàcil determinar que `Pere` i `Manel` són noms i que `Puig` i `Garcia` són cognoms. Però per mitjà de la jerarquia de les dades es pot inferir que `Pere Puig` i `Manel Garcia` són `alumnes` ja que tant `nom` com `cognom` estan englobats dins de la marca `alumnes`.

Aquest document mostra **quina és l'estructura de les dades** que conté i a més aquesta també es pot descobrir tot interpretant les etiquetes el seu contingut semàntic. A partir dels coneixements que es tinguin es dedueix que `Pere` és el nom d'una persona que és un alumne.

Sistema d'etiquetatge

Tant si el sistema és descriptiu com de presentació **les marques no han estat col·locades de qualsevol manera** sinó que s'ha anat seguint un sistema determinat. Sovint les marques envolten el contingut que volem que tingui un significat o que sigui representat d'una manera determinada. No es poden col·locar les marques de qualsevol manera, ja que una de les coses que cal evitar són possibles malinterpretacions.

Per això, a més de definir les marques que s'hi posaran, els llenguatges de marques defineixen unes regles d'ús que especifiquen com han de ser les marques, en quines condicions es permet fer-les sevir i a vegades fins i tot què signifiquen.

1.3.4 Història

Es considera que l'origen dels llenguatges de marques està en les modificacions que els impressors feien amb llapis en manuscrits. Quan algú volia imprimir un llibre que havia escrit, els impressors, amb un llapis generalment de color blau, escrivien en el text quines característiques havia de tenir cada part del text, si s'havia de fer en negreta, si era el títol del llibre, etc. Es creu que aquests són els antecedents de les marques.

SGML

Al principi dels anys vuitanta a IBM necessitaven alguna manera d'emmagatzemar i compartir una gran quantitat d'informació entre diferents plataformes i que permetés integrar les dades en sistemes de dades, editors, etc., i van desenvolupar GML, que posteriorment va acabar amb el nom SGML en el moment en què va

ser estandarditzat l'any 1986 per l'organització d'estàndards internacional ISO (International Organitzation for Standardisation). L'especificació es troba sota el nom ISO-8879.

A pesar que no es considera el primer llenguatge de marques, va ser el primer llenguatge reconegut com a estàndard ISO.

SGML (*standard generalized markup language*) és un llenguatge basat en les dades de text que es pot fer servir per posar metadades a les dades. És un sistema per organitzar i etiquetar elements d'un document posant èmfasi en els aspectes de l'estructura d'un document i deixant que sigui l'intèrpret el que s'encarrega de fer la representació visual d'aquestes dades. Ho fa definint unes regles estrictes que especifiquen de quina manera es poden fer les etiquetes.

SGML es va dissenyar per ser una manera estàndard d'etiquetar dades genèriques de manera que no importés si les dades per etiquetar provenien del món de les matemàtiques o bé eren els resultats financers d'una empresa. Totes les dades es podien etiquetar amb sentit fent servir SGML.

El fet que SGML fos tan complex no el feia ideal per intercanviar dades per mitjà d'Internet. Si només un grup de persones podia generar informació el creixement de l'entorn Web hauria estat molt inferior.

SGML es feia servir sobretot en documents que havien de tenir molts canvis i que posteriorment s'havien de representar en formats diferents.

Per tant, amb SGML tenim els avantatges següents:

- Tenim una manera de reutilitzar les dades.
- Permet un control més gran sobre les dades i en garanteix la integritat.
- És portable.
- És flexible.
- Ens garanteix la perdurabilitat de la informació.

Però no tot són avantatges en l'SGML:

- La majoria dels documents que s'hi creaven només estaven destinats a la impressió.
- És terriblement complex, de manera que no es fa servir en ordinadors personals.

HTML

El 1989, Tim Berners-Lee i Anders Berglund, dos investigadors del CERN (acrònim de Conseil Européen pour la Recherche Nucléaire, Organització Europea per a la Recerca Nuclear), van crear un llenguatge basat en etiquetes basat en SGML destinat a compartir informació per Internet: HTML (*hypertext markup language*). HTML es basa en la manera de definir i interpretar etiquetes de SGML però no és totalment compatible amb SGML (algunes de les regles que s'hi han definit incompleixen les regles SGML).

HTML es concentra a definir un format per descriure la visualització de la informació en una pàgina web i és molt senzill. La seva senzillesa ha estat un dels factors que ha portat a la ràpida popularitat del World Wide Web i alhora d'Internet. És un dels motius pels quals cada dia es generen milions de pàgines web noves.

El gran èxit de les tecnologies basades en HTML ha fet que no parin d'evolucionar i, per tant, que HTML hagués d'evolucionar molt ràpidament per adaptar-se cada vegada a més canvis i a les noves necessitats dels usuaris. Això, sumat al propòsit de no incrementar la dificultat del llenguatge, ha provocat que no sempre s'hagin fet les coses de la mateixa manera i que, per tant, la creació d'intèrprets de HTML (en especial els navegadors) cada vegada sigui més complexa.

A tot això s'hi ha de sumar que, malgrat no estar pensat per representar la informació, HTML no defineix gaire estrictament algunes de les regles de com s'ha de visualitzar la informació, i per tant sovint els navegadors han fer interpretacions que no sempre coincideixen amb les que fan els altres navegadors. És conegut per tots els dissenyadors de pàgines web que les pàgines no sempre es veuen igual en tots els navegadors (figura 1.8).

Figura 1.8. Visualització de pàgines en navegadors

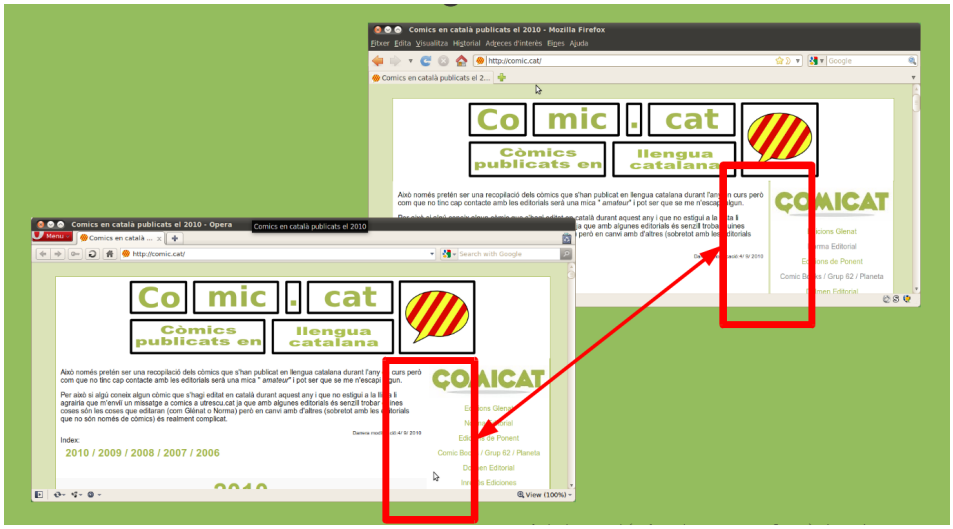

A vegades les diferències són mínimes però en altres casos les diferències poden ser molt importants.

D'altra banda, HTML funciona bé a l'hora de presentar informació als humans però té uns quants problemes que el fan poc eficient per a les noves aplicacions actuals: és molt difícil reutilitzar la informació que conté per generar resultats en formats diferents dels que ha definit el dissenyador i és molt complex per als programes automàtics interpretar de quin tipus són les dades contingudes en un document HTML.

Per tant, calia alguna manera de poder fer cerques intel·ligents en els documents HTML i seleccionar-ne el resultats segons criteris personalitzables.

Calia una manera de buscar, moure, visualitzar i manipular la informació continguda en els documents HTML.

I per aquest motiu va aparèixer l'XML.

XML

El consorci W3C va desenvolupar una alternativa a l'HTML que pogués satisfer les necessitats futures del web. El 1996 el consorci W3C es va proposar introduir el poder i la flexibilitat de l'SGML al web.

SGML oferia tres avantatges que l'HTML no tenia:

- Extensibilitat
- Estructura
- Validació

El febrer de 1998 es llença l'especificació 1.0 d'XML (http://www.w3.org/TR/2004/REC-xml-20040204/) i posteriorment el 2004 va sortir la versió 1.1 (http://www.w3.org/TR/xml11/). Aquestes especificacions s'han anat revisant periòdicament.

La versió més usada és la 1.0, ja que la versió 1.1 no aporta gaires novetats interessants per a la majoria d'usos (bàsicament sobre les versions d'Unicode posteriors a XML 1.0)

L'XML és un llenguatge simple de descripció d'informació:

- És un estàndard que permet dissenyar i desenvolupar llenguatges de marques.
- És un format de text estandarditzat que serveix per representar i transportar informació estructurada.

Nombre d'etiquetes
A l'HTML li ha anat bé amb un nombre finit d'etiquetes i, per tant, a l'hora de dissenyar l'XML es van fer diversos intents de crear un nombre finit d'etiquetes. Però tots els intents de crear un conjunt finit d'etiquetes van fallar perquè restringir les etiquetes restava flexibilitat al llenguatge.

Es va veure que cada conjunt d'usuaris necessita un subconjunt d'etiquetes diferent i que sovint eren divergents (els matemàtics en feien servir un, els químics en necessitaven un altre, etc.), o sigui, que la solució final adoptada va ser la més lògica: si restringir les etiquetes resta flexibilitat el més fàcil és no restringir-les.

L'XML defineix un nombre infinit d'etiquetes.

Per tant, l'XML permetrà que cada persona pugui definir les etiquetes que li facin falta per poder representar les dades més adequadament.

Estructura de les dades
Una altra idea que es va tenir en compte a l'hora de desenvolupar l'XML era que les dades que contingués es poguessin reutilitzar per generar altres resultats i, per tant, calia que pogués ser interpretat fàcilment per mitjà de programes d'ordinador. Per tant, les dades contingudes en documents havien de tenir una estructura.

Per tant, l'XML es va dissenyar amb la idea **de donar estructura a les dades i no preocupar-se de com es presentaran les dades als usuaris**. Per fer-ho ja es desenvoluparien altres alternatives: CSS, XML-FO, etc.

> Una de les idees més importants d'XML és **separar les dades de la presentació**.

Això fa que a l'hora de crear un document XML s'ha de pensar com s'han d'estructurar les dades i mai especificar res de com s'hauran de representar.

Transport de les dades
El fet que l'XML es concentri en l'estructura de les dades i que, per tant, sigui relativament fàcil determinar quines dades conté, el fa un sistema ideal per al transport de dades entre diferents plataformes.

Per tant, si tenim un document XML com aquest:

```
<alumnes>
    <persona>
        <nom>Manel</nom>
        <cognom>Garcia</cognom>
    </persona>
    <persona>
        <nom>Pere</nom>
        <cognom>González</nom>
    </persona>
</alumnes>
```

Podem veure que observant aquest document és relativament senzill respondre les preguntes:

- Quina informació conté el fitxer?
- Quina és l'estructura de la informació?
- Quines etiquetes s'han creat per descriure'n la informació?

Creació de llenguatges
És evident que la llibertat que dóna tenir un nombre infinit d'etiquetes no és necessària en la majoria dels àmbits d'actuació. Per aquest motiu, normalment quan algú vulgui emmagatzemar informació definirà un nombre finit d'etiquetes i en quin ordre han d'aparèixer.

Per poder solucionar aquests problemes en XML es poden definir fitxers que defineixin quina serà l'estructura del document, i que, per tant, es pugui comprovar

si el document segueix l'estructura correcta o no. Això alhora permet que si definim el vocabulari de manera pública qualsevol ens pugui enviar documents i detectar si estan ben formats o no.

De fet, ja hi ha tota una sèrie de documents basats en XML que s'han convertit en estàndards públics en diferents àmbits, alguns dels quals els podeu veure en la taula 1.9.

Taula 1.9. Alguns llenguatges estàndard basats en XML

Nom	Ús
SVG	Pensat per a gràfics vectorials en 2D amb animacions o sense
MathML	Llenguatge per representar fórmules matemàtiques
CML	Llenguatge per a l'intercanvi d'informació química
SMIL	Tractament d'informació multimèdia
SSML	Síntesi de veu
ChessGML	Per representar partides d'escacs
XFRML	Per fer informes financers
SML	Usat en la indústria de l'acer

Però no s'acaba aquí, ja que la llista és immensa: SMBXML, CIML, NAML, TML, SCORM, LMML, OpenMath, PetroXML, ProductionML, GeophysicsML, X3D, MML, SMDL, BGML, etc.

Extensible

Un altre dels avantatges d'XML és que és fàcilment extensible i adaptable a les necessitats que tinguem. L'XML permet que es barregin diferents vocabularis en el mateix document.

Això fa que puguem definir un document XML amb un vocabulari creat per nosaltres que defineixi una llista d'alumnes i que alhora hi puguem afegir una imatge amb el logotip de l'escola en format SVG (un estàndard XML de gràfics vectorials) i alhora definir-hi la presentació en XHTML.

Per tant, tenim prou flexibilitat per representar les dades que ens calguin en cada moment

Ús d'XML

Actualment els usos d'XML són molt diversos:

- Mostrar el contingut de pàgines web. Un dels llenguatges XML és l'XHTML, que intenta modificar l'HTML per fer-lo més senzill d'interpretar.
- Comunicar sistemes distribuïts que fins i tot executin sistemes operatius diferents o estiguin en plataformes totalment diferents.

- En comerç electrònic, en un sistema conegut com a Bussines2Bussines que permet a les empreses compartir dades de manera automàtica.
- Reduir la càrrega de servidors distribuint-la entre servidors.

Molts programes que feien servir formats binaris per emmagatzemar les seves dades han passat a algun tipus d'XML:

- Microsoft Office: va passar de desar els documents en binari .DOC a XML .DOCX (OOXML) en estandaritzar-lo.
- OpenOffice.org: desa els seus documents en un format XML.

Podem veure que molts programes fan servir XML per desar la seva configuració o les seves dades amb una simple cerca en el sistema operatiu.

Amb una simple cerca podem veure quants fitxers XML tenim en el nostre sistema operatiu. Per exemple, en Linux podem executar el següent per veure el nombre de fitxers XML que hi tenim:

```
$ locate .xml | wc –l
```

En Windows podem fer el mateix amb:

```
c:\> dir /a–d /s *.xml | find /c /v ""
```

Problemes

A pesar dels múltiples avantatges que ofereix l'XML, també se li han fet crítiques, com el fet que els fitxers XML tenen la tendència a ser molt grans. Gairebé sempre ocupen una quantitat molt més gran d'espai en disc que els seus equivalents en format binari.

El fet de fer servir fitxers molt grans pot tenir un impacte important en el rendiment dels programes, ja que abans de poder-hi treballar han de carregar el fitxer o descarregar-lo de la xarxa.

Hi ha gent que considera que el problema de la grandària dels fitxers a vegades és compensat per:

- La facilitat d'interoperativitat entre programes.
- El preu de l'emmagatzematge és cada vegada més baix i per ara sembla que la tendència és que encara baixi més.

Però no tothom hi està d'acord, i per aquest motiu han aparegut tota una sèrie d'alternatives a l'XML que es coneixen com a *llenguatges de marques lleugers*, que normalment tenen com a objectiu aconseguir que els fitxers de marques ocupin molt menys espai:

- En ocupar menys espai estalvien amplada de banda i espai de disc.
- Normalment es poden convertir a XML sense problemes.
- Ocupen menys memòria RAM quan són processats.

Els llenguatges de marques lleugers més usats actualment són JSON (*JavaScript object notation*) i els llenguatges de marques dels wikis.

2. Documents XML

Vegeu la recomanació de l'W3C relativa a l'XML en la secció "Adreces d'interès" del web del mòdul.

XML són les sigles d'*extensible markup language* (llenguatge d'etiquetatge extensible). És un llenguatge estàndard, una recomanació del World Wide Web Consortium (W3C, http://www.w3.org/TR/REC-xml/). Està basat en l'estàndard ISO SGML.

L'XML està tan basat en SGML que qualsevol document XML és un alhora un document SGML correcte (encara que a l'inrevés no passa).

L'XML va sorgir per intentar superar els problemes que tenia l'HTML a l'hora de processar automàticament la informació que contenen les pàgines web, però que a més pogués funcionar de la mateixa manera que es fa servir l'HTML. A més, s'hi van afegir altres requisits, com que:

- Fos fàcil crear documents XML i que els humans els poguessin llegir i entendre fàcilment.
- No fos complicat fer programes d'ordinador que treballessin amb XML.
- L'XML es pogués fer servir en el màxim possible de camps d'aplicació i mantingués la compatibilitat amb SGML.

El resultat ha estat que l'XML:

- Defineix la sintaxi genèrica per marcar les dades amb valors comprensibles per als humans.
- És una manera de donar format als documents que és prou flexible per ser personalitzada per a diferents destinacions: web, impressores, bases de dades, etc.
- Està pensat perquè tothom el pugui fer servir sigui quina sigui la seva àrea d'interès.

2.1 Metallenguatge

En realitat l'XML no és un llenguatge de marques, sinó que és un llenguatge que ens permetrà definir els nostres llenguatges de marques propis. Això vol dir que podrem definir llenguatges de marques específics per a cada un dels camps d'interès. Si treballem en el món dels gràfics podem definir el nostre llenguatge

específic per definir aquests gràfics, i si treballem en el món de la premsa podrem definir el nostre llenguatge per representar les notícies.

Per aquest motiu sovint es diu que l'XML és un **metallenguatge**, ja que ens permet definir l'estructura i el vocabulari d'altres llenguatges de marques.

> L'XML és un llenguatge per crear llenguatges de marques.

Aquesta llibertat a l'hora de definir les marques que ens interessin és un dels punts forts d'XML, que el fan molt més potent i adaptable a les diferents complexitats dels entorns en els quals pugui caldre.

2.2 Elements

La base de l'XML són els elements. Un element normalment estarà format per l'obertura d'una etiqueta –amb atributs o sense–, un contingut –que també pot ser un grup d'etiquetes–, i el tancament de l'etiqueta.

En aquest exemple podem veure el que acabem de comentar. Definim una etiqueta `nom`, després el contingut `Pere Martí` i posteriorment tanquem l'etiqueta:

```
1 <nom>Pere Martí</nom>
```

Aquest és un dels punts forts de l'XML: queda bastant clar que el contingut de dins de l'etiqueta és un nom.

Es podria fer l'exemple una mica més complex afegint-hi un atribut.

> Els atributs s'afegeixen sempre en l'obertura de l'etiqueta.

```
1 <nom càrrec="director">Pere Marti</nom>
```

Un altre dels aspectes bàsics de l'XML és que no es preocupa de la presentació sinó que parteix de la idea que l'important és el contingut de les dades i no la manera com es visualitzaran. Aquesta característica el fa ideal per presentar la informació i posteriorment per mitjà d'algun procés convertir la informació en un format de presentació específic com HTML, PDF, PostScript, etc. A més, aporta una característica molt interessant des del punt de vista de la informàtica: permet tenir les dades separades de la manera de representar-les.

> L'XML permet separar el contingut de la manera com serà presentat aquest contingut als usuaris.

2.2.1 Etiquetes

Les etiquetes es defineixen dins del document XML i es defineix un format per separar-les clarament del contingut de dades. Estrictament parlant hi ha dos tipus d'etiquetes:

- **Les etiquetes d'obertura**
- **Les etiquetes de tancament**

La informació es distribueix entre els dos tipus d'etiquetes. Així s'aconsegueix una manera senzilla de definir quines parts del document són dades i quines són estructura.

Les *etiquetes d'obertura* es defineixen amb els símbols de més petit "<" i més gran ">" amb un nom d'etiqueta al mig.

```
<etiqueta>
```

I les *etiquetes de tancament* es defineixen igual que les d'obertura però a l'hora de començar l'etiqueta s'hi especifiquen dos símbols: un símbol de més petit i una barra "</". D'aquesta manera es poden distingir fàcilment els dos tipus d'etiquetes i queda clar en quin lloc s'ha d'afegir el contingut.

```
<etiqueta>Contingut</etiqueta>
```

L'XML no defineix cap etiqueta sinó que permet que les defineixi cadascú en funció del que necessiti representar. Això fa més senzill crear documents XML, ja que no cal conèixer cap etiqueta per poder començar a treballar i perquè permet adaptar-se a qualsevol tasca.

A l'hora de definir les etiquetes es pot deixar un espai o un salt de línia darrere del nom de l'etiqueta però mai abans ni al mig. Per tant aquestes etiquetes serien correctes:

```
<etiqueta1>
<etiqueta >
</etiqueta>
</etiqueta1 >
</etiqueta2
>
```

I en canvi aquestes altres no serien correctes:

```
< etiqueta>
<etiqueta 1>
< /etiqueta2>
```

Com s'acaba de veure, l'especificació XML defineix clarament com s'han de crear les etiquetes en els documents XML, però en canvi no defineix cap tipus ni significat associat a cap de les etiquetes. Si, per exemple, fem servir en HTML

l'etiqueta <b>, aquesta ens està indicant que el contingut que contindrà s'haurà de representar en negreta. Això obliga que per fer documents XML s'hagin de conèixer les etiquetes.

Per a l'XML les etiquetes només són una manera de separar el contingut i definir l'estructura de les dades que conté. La interpretació de què signifiquen les dades i com s'han de representar es deixa a qui llegeixi el document (independentment que aquest sigui un humà o bé un programa).

El tractament d'excepcions que s'ha de fer per interpretar HTML és una de les coses que fa més complexa la tasca de programar els navegadors web actuals.

A pesar de la llibertat a l'hora de deixar que els usuaris triïn les seves pròpies etiquetes, l'XML és molt més rigorós que altres llenguatges a l'hora de definir com s'han d'escriure. L'objectiu de tenir regles d'escriptura està determinat per la necessitat que els documents XML en un moment o un altre seran processats per un programa, i els programes es fan més complexos a l'hora de tractar amb excepcions. Per tant, una de les coses que fa l'XML és **evitar les excepcions tant com sigui possible**.

> Les etiquetes que s'obrin sempre s'hauran de tancar.

Per evitar les excepcions una de les regles bàsiques d'XML és que qualsevol etiqueta que s'obri **sempre s'ha de tancar**. De manera que aquest no seria un document XML vàlid:

```
1 <nom>Pere Garcia
```

I en canvi aquest sí:

```
1 <nom>Pere Garcia</nom>
```

A pesar que no hi ha etiquetes definides, ja que l'XML **permet crear les etiquetes que ens facin falta**, per un motiu de llegibilitat i d'interpretació de les dades **es recomana que les etiquetes siguin autoexplicatives i pronunciables**. Això és per evitar coses com la de l'exemple següent:

```
1 <pccc>Figueres</pccc>
```

Segons aquest segon exemple, com determinem què és "Figueres"? Per a un programa d'ordinador segurament no seria un problema massa gran perquè simplement agafaria la dada i la interpretaria tal com l'hagin programat però en canvi per a un humà un document amb etiquetes com aquesta seria impossible d'interpretar.

> Es recomana triar els noms de les etiquetes de manera que puguin ser interpretades per qui les llegirà independentment de si les processa una persona o un programa.

L'exemple anterior serà més fàcil d'interpretar si canviem l'etiqueta:

```
1 <ciutat>Figueres</ciutat>
```

2.2.2 Contingut

El contingut d'un element serà tot allò que hi hagi entre les etiquetes d'obertura i de tancament. En el contingut podem tenir simplement text com aquí:

```
<persona>Pere Martí</persona>
```

O bé el contingut poden ser altres elements. En l'exemple següent l'element `<persona>` conté dos elements més: `<nom>` i `<cognom>`, que a més tenen contingut dins seu:

```
<persona>
    <nom>Pere</nom>
    <cognom>Martí</cognom>
</persona>
```

Una tercera possibilitat seria combinar els dos casos anteriors i que el contingut sigui una mescla de text i elements.

```
<persona>
    Pere Martí
    <carrec>Director</carrec>
</persona>
```

També és possible definir etiquetes sense contingut de manera que el seu significat està determinat pel nom de l'etiqueta.

```
<persona>
</persona>
```

Els elements buits també es poden definir fent servir el símbol `/>` en tancar l'etiqueta. De manera que no hi ha cap diferència entre definir `<director>` d'aquesta manera:

```
<director/>
```

o d'aquesta:

```
<director></director>
```

Els elements buits, encara que es defineixin amb el seu format especial, han de seguir les mateixes normes que els elements normals. Per tant, serien correctes les definicions següents:

```
<director />
<director
/>
```

I no ho serien aquestes:

```
< director/>
<director/ >
```

L'XML no defineix cap restricció a l'hora de definir el contingut dels elements. Per tant:

- Podem fer servir qualsevol caràcter representable amb el codi de caràcters.
- El contingut pot ser tan llarg com ens faci falta.
- Es pot escriure en qualsevol idioma del món.
- No importa que hi hagi espais en blanc o salts de línia dins del contingut.

Entitats

L'única cosa que s'ha de tenir en compte a l'hora de definir continguts és que hi ha una sèrie de caràcters que poden provocar que hi hagi confusions a l'hora d'interpretar el document XML, i per tant s'han declarat il·legals. No cal oblidar que un dels objectius de l'especificació és "que sigui fàcil escriure programes que processin els documents", i per tant s'han d'evitar les interpretacions.

Si passem el codi següent a un programa d'ordinador tindrem un problema

```
<algebra>
x<y i y>z
</algebra>
```

Per a un humà això no seria un problema perquè pot interpretar les dades per mitjà del seu coneixement, però en canvi un programa en llegir el contingut del document interpretaria que `<y i y>` és el començament d'una nova etiqueta.

Per evitar aquest problema s'han definit una sèrie de valors, anomenats **entitats**, que es fan servir per poder incloure els caràcters problemàtics dins del contingut de les etiquetes (taula 2.1).

Referències de caràcters

En realitat qualsevol caràcter es pot representar com una entitat fent servir el seu valor numèric en Unicode, emprant els símbols `&#` i els tres dígits del seu valor numèric. Per exemple: &#169

Taula 2.1. Entitats definides en XML

Símbol	Substitució
<	<
>	>
”	%quot;
’	'
&	&

Seccions CDATA

Es pot donar el cas que el contingut d'un element sigui HTML o bé codi en algun llenguatge de programació. Això obligaria a substituir per entitats una gran quantitat de símbols i a més restaria llegibilitat al document. Per evitar-ho l'XML permet fer servir les seccions CDATA dins del contingut d'un element. Tot el que estigui dins d'una secció CDATA no serà interpretat per cap programa.

`CDATA` és un terme heretat d'SGML i resumeix el text *character data*.

Les seccions CDATA funcionen com les etiquetes normals. Es defineixen començant per **<![CDATA[** abans d'especificar el contingut i s'acaben amb la combinació de caràcters **]]>**. Per tant, podem definir contingut amb símbols prohibits dins de les seccions CDATA sense problemes.

```
<valor>
    <![[CDATA[
        if (x <y and y>z)
        {
            printf("Correcte!");
        }
    ]]>
</valor>
```

A més es pot veure fàcilment que per a un humà és més difícil interpretar això:

```
<titol>Els documents HTML comencen per &lt;html&gt;</titol>
```

Que el seu equivalent amb CDATA:

```
<titol>
  <![[CDATA[
    Els documents HTML comencen per <HTML>
  ]]>
</titol>
```

Un altre problema que solucionen les seccions CDATA és que permeten afegir contingut en un llenguatge de marques que no cal que estigui ben format. Per exemple, si el contingut té etiquetes que no es tanquen només es poden definir en una secció CDATA o bé el programa les interpretarà com a etiquetes del document i donarà un error.

Les seccions CDATA normalment es fan servir per al següent:

- Definir grans fragments de text que requereixin moltes substitucions d'entitats.
- Si s'ha d'incloure contingut en HTML, Javascript o algun llenguatge similar. La substitució amb entitats li resta llegibilitat.
- Si el contingut està en un llenguatge de marques i no està ben format.

2.2.3 Atributs

Una manera alternativa d'afegir contingut als documents XML és per mitjà dels atributs. Els atributs són un parell de valors separats per un = que **només s'especifiquen en les etiquetes d'obertura**.

El primer valor del parell ens indica quin és el nom del contingut i es farà servir per interpretar què indiquen les dades que té associades, mentre que el segon ens definirà el contingut de l'atribut.

```
<nom carrec="professor">Frederic Garcia</nom>
```

Es pot veure com l'atribut `carrec` dóna un nivell més d'informació a `nom`. Ara se sap que fa referència al nom d'un professor.

Per especificar els atributs es poden fer servir tant les comentes dobles com les cometes simples. Això sí, sempre s'ha de tancar les cometes tal com s'han obert. `<corredor posicio="1">` o `<corredor posicio='1'>` però mai `<corredor posicio="1'>`

A diferència del que passa en altres llenguatges de marques com l'HTML, l'XML és molt més estricte i obliga que **tots els valors dels atributs han d'estar envoltats per cometes**. En altres llenguatges de marques es permet que els valors numèrics no vagin entre comentes però en XML no es pot fer. Per tant l'exemple següent seria incorrecte perquè l'atribut no té cometes.

```
<corredor posicio=1>Manel Roure</corredor>
```

Si es vol especificar s'ha de posar entre cometes simples:

```
<corredor posicio='1'>Manel Roure</corredor>
```

o dobles:

```
<corredor posicio="1">Manel Roure</corredor>
```

Fins i tot quan els atributs no cal que tinguin cap valor, perquè es considera que ja se'n pot interpretar el significat pel nom de l'atribut, s'hi ha d'especificar valor entre cometes. Per tant, l'exemple següent no seria correcte perquè l'atribut no té valor:

```
<alumne delegat>Jaume Ravent</alumne>
```

Ho hauríem d'especificar amb la cadena buida:

```
<alumne delegat="">Jaume Ravent</alumne>
```

O posant-hi algun valor:

```
<alumne delegat="si">Jaume Ravent</alumne>
```

L'XML **permet definir tants atributs com faci falta** sense cap tipus de restricció. Les úniques condicions que hem de seguir és que cada un dels atributs ha d'estar separat dels altres almenys per un espai.

```
<persona nom="Xavier" cognom="Sala" cognom="Pujolar"/>
```

L'ordre en què apareixen els atributs no té cap importància, de manera que els dos codis següents serien equivalents:

```
<persona nom="Xavier" cognom="Sala" />
```

```
<persona cognom="Sala" nom="Xavier" />
```

Quan s'han de fer servir atributs i quan elements?

Hi ha hagut molts debats sobre quan s'han de fer servir atributs i quan s'han de fer servir elements sense que s'hagi trobat cap argument totalment acceptat per tothom.

Al final el resultat pràctic és que és virtualment el mateix fer això:

```
<persona nom="Pere" />
```

Que fer:

```
<persona>
   <nom>Pere</nom>
</persona>
```

I per tant sempre es pot fer servir el mètode que ens agradi més.

Una altra característica important dels atributs és que **no es poden repetir els noms dels atributs dins d'un mateix element**. De manera que no és correcte especificar dos atributs `carrec`:

```
<polític carrec="alcalde" carrec="diputat">Jordi Rufi</polític>
```

Per tant, s'ha de buscar una altra manera d'especificar-ho. Per exemple, amb una llista de valors:

```
<polític carrec="alcalde diputat">Jordi Rufi</polític>
```

o bé posant noms d'atributs diferents:

```
<politic alcalde="si" diputat="si">Jordi Rufi</polític>
```

Atribut xml:lang

L'atribut `xml:lang` és un atribut predefinit i serveix per especificar l'idioma que s'ha fet servir per escriure el contingut tant de l'element com dels altres atributs.

Vegeu les formes definides per l'IETF en el BCP 47 en la secció "Adreces d'interès" del web del mòdul.

El valor de l'atribut `xml:lang` pot ser buit o bé ha d'estar en una de les formes definides per l'IETF en el BCP 47 (http://www.rfc-editor.org/rfc/bcp/bcp47.txt), que fan servir els codis ISO que defineixen les regions i els idiomes. Sense entrar-hi en profunditat això implica que hi podem definir el codi ISO d'un idioma o bé una combinació de codis ISO que defineixin la regió i l'idioma.

> L'atribut `xml:lang` ens permet definir en quin idioma està el contingut d'un element o d'un document XML.

Per tant, el valor de l'atribut `xml:lang` d'aquest exemple seria vàlid perquè el codi ISO 639 de dues lletres per a la llengua catalana és `ca`.

```
<missatge xml:lang="ca">Hola</missatge>
```

Però també seria vàlid fer servir qualsevol de les combinacions de regió i idioma:

```
<missatge xml:lang="ca-ES">Hola</missatge>
<missatge xml:lang="ca-AD">Salut</missatge>
```

L'atribut només fa referència a l'element en què s'ha especificat i al seu contingut, de manera que aquí:

```
<saludar xml:lang="ca">
  <arribar>Hola</arribar>
  <marxar>Adéu</marxar>
</saludar>
```

es pot considerar que els elements `arribar` i `marxar` tenen també l'atribut `xml:lang` perquè són contingut de `<saludar>`, i per tant el seu contingut i el valor dels seus atributs està en català.

Sempre es pot evitar aquesta forma d'herència de l'atribut redefinint l'atribut `xml:lang` com en aquest exemple:

```
<saludar xml:lang="ca">
  <arribar>Hola</arribar>
  <arribar xml:lang="en">Hello</arribar>
</saludar>
```

S'hi defineixen dos elements `arribar`, un que té el contingut en català, ja que l'ha heretat de l'element `saludar`, que els conté, i l'altre que té el contingut en anglès perquè se l'hi ha especificat l'idioma explícitament.

L'objectiu de l'atribut `xml:lang` és permetre que els programes puguin interpretar l'idioma en el qual hi ha el contingut dels documents o dels elements XML. Hi ha molts programes que fan servir aquesta característica per poder fer que els programes adaptin el contingut que han de mostrar en l'idioma del qui els fa servir.

Si es té un programa que vol mostrar missatges per pantalla en l'idioma que faci servir l'usuari se li podria preparar un fitxer de dades com el següent, que li permetria fer-ho un cop hagués determinat l'idioma del sistema operatiu:

```
<programa>
   <missatge xml:lang="ca">Benvingut</missatge>
   <missatge xml:lang="es">Bienvenido</missatge>
   <missatge xml:lang="fr">Soyez le bienvenu</missatge>
   <missatge xml:lang="en">Welcome</missatge>
</programa>
```

L'atribut "xml:space"

L'atribut `xml:space` fa referència a com s'han de tractar els espais que hi ha en el contingut d'un element determinat.

Quan algú edita un document XML és corrent que faci servir espais i salts de línia perquè el document sigui més "bonic" però realment aquests espais i salts de línia no formen part del contingut. **Amb l'ús de l'atribut `xml:space` es defineix si aquests espais són part del contingut o no**.

Només hi ha dos valors acceptats per a l'atribut `xml:space`: **default** i **preserve** (taula 2.2).

Taula 2.2. Valors acceptats per a l'atribut "xml:space"

Valor	Significat
default	Implica que el document ha de mostrar només un sol espai de separació entre les paraules. Qualsevol altra cosa ha de ser suprimida.
preserve	Fa que els espais es deixin tal com estan en el document. Per tant, si hi ha 5 espais després d'una paraula en el contingut s'han de preservar aquests espais.

Qualsevol altre valor es considerarà un error lleu i no es tindrà en compte.

Seguint el que hem definit, en el document següent:

```
<missatge xml:space="default">
Hola:
    Com va tot?
</missatge>
```

Com que l'element `<missatge>` té de paràmetre `xml:space=''default''`, li estem especificant que se suprimeixin els espais, o sigui, que seria com tenir:

```
<missatge>Hola: Com va tot?</missatge>
```

En canvi, si l'atribut hagués estat `preserve` el valor del contingut de `<missatge>` seria interpretat respectant els espais i els salts de línia.

```
<missatge>
Hola:
    Com va tot?
</missatge>
```

Els processadors XML han de passar tots els espais que no siguin etiquetes al programa que llegeixi el document. Per tant, a pesar del nom per defecte es fa servir `preserve`.

2.2.4 Noms vàlids XML

L'XML permet definir les nostres etiquetes i atributs lliurement però no totes les combinacions possibles són acceptables. Els noms de les etiquetes i dels atributs han de complir unes regles per ser considerats "correctes".

Les regles per definir noms correctes són senzilles:

1. Els noms han de començar per una lletra de l'alfabet, el caràcter de subratllat (_) o un guió (-). També s'accepta el caràcter de dos punts (:), però està reservat.

Tot i que els dos punts estan acceptats no es recomana que es facin servir en la creació d'etiquetes perquè es reserven per ser usats en *espais de noms*.

2. Els caràcters en majúscules són diferents dels caràcters en minúscules.
3. No hi pot haver espais enmig del nom.
4. No poden començar per la paraula *XML* tant si qualsevol de les lletres està en majúscules o en minúscules. Aquestes paraules es reserven per a estandarditzacions futures.

Seguint aquestes regles tindrem que l'exemple següent:

```
<Ciutat comarca="Alt Empordà">Figueres</Ciutat>
```

L'etiqueta `<Ciutat>` és correcta perquè compleix totes les regles. La primera lletra del nom comença per un caràcter de l'alfabet, `C`, no hi ha cap espai enmig del nom, i no comença per les lletres `xml`.

Alhora, l'atribut `comarca` també és correcte perquè comença amb un caràcter de l'alfabet, `c`, no té espais i no comença per `xml`.

En canvi no és correcta l'etiqueta `<Alt Empordà>` perquè té espais enmig del nom:

```
<Alt Empordà></Alt Empordà>
```

Ni ho serien les etiquetes `<1aPosicio>` i `<2aPosicio>`, ja que comencen per un dígit:

```
<carrera>
  <1aPosicio>Manel Garcia</1aPosicio>
  <2aPosicio>Pere Pi</2aPosicio>
</carrera>
```

En la taula 2.3 hi ha exemples d'etiquetes correctes i incorrectes.

Taula 2.3. Exemples d'etiquetes correctes i incorrectes

Etiquetes correctes	Etiquetes incorrectes
<correu1/>	<1Correu/>
<correu-electronic/>	<correu electronic/>
<element />	< element/>
<_Carai/>	<%descompte/>
<svg:rectangle />	<xml-rectangle/>

La versió 1.1 d'XML permet que siguin vàlids tota una sèrie de caràcters extra per adaptar-se a les noves versions de Unicode, però en general no aporten res si no fem servir algun idioma asiàtic.

A pesar d'aquestes restriccions la llibertat que permet l'estàndard és prou important.

Una de les coses que no s'ha d'oblidar mai és que un dels objectius d'XML és fer que els documents amb XML puguin ser llegits i entesos fàcilment per les persones i, per tant, es recomana que no es facin servir noms que no tinguin sentit o que siguin difícilment entesos per una persona.

2.2.5 Comentaris

Sovint en els documents XML s'especifiquen dades extra que realment no formen part del document. Aquestes dades s'anomenen *comentaris* i es fan servir per a moltes coses diverses, com ara:

- Generar documentació sobre el document.
- Indicar a la gent que pugui rebre el document què es volia fer en crear-lo.
- Altres.
-

Els analitzadors XML són programes que, a partir de l'estructura dels documents XML, ens permeten l'accés al contingut a partir de les seves etiquetes.
El més habitual sol ser processar el document per generar-ne una sortida que pugui ser visualitzada més fàcilment, etc..

Generalment els analitzadors XML simplement solen descartar els comentaris, ja que l'especificació XML diu que no cal que siguin processats.

Els comentaris s'especifiquen encloent-los entre els símbols "<!–" i "–>" i es poden posar comentaris en qualsevol lloc del document XML excepte dins de les etiquetes. Com a exemple, en el document següent s'ha inclòs el comentari "Llista d'alumnes" per a indicar en quin lloc comença la llista d'alumnes:

```
<professors>
   <nom>Marcel Alaba</nom>
</professors>
<!–– Llista d'alumnes ––>
<alumnes>
   <nom>Frederic Garcia</nom>
   <nom>Federicu Pi</nom>
</alumnes>
```

2.2.6 Instruccions de procés

Les instruccions de procés són una manera de donar instruccions als programes que llegiran el document. Es defineixen dins dels símbols "<?" i posteriorment **sempre s'hi ha d'especificar a quin programa van dirigides** amb l'única restricció que no poden ser les lletres "XML" en qualsevol combinació de majúscules o minúscules.

Per tant, per afegir informació que vagi destinada a un programa anomenat `php` s'han de definir les instruccions de procés amb una instrucció de procés:

```
<?php ... ?>
```

Aquest sistema permet que en un document XML es puguin afegir instruccions de procés diferents per a programes diferents:

```
<?programa1 ... ?>
<?programa2 ... ?>
```

El contingut de les dades pot ser qualsevol cosa que tingui sentit per al programa que les llegirà, i per tant no necessàriament ha de tenir sentit per als processadors XML. Com que no formen part del document XML en si poden aparèixer en qualsevol lloc del document excepte en mig d'una etiqueta.

2.3 Declaració XML

L'especificació és una línia que defineix una manera d'identificar que un document és XML per mitjà d'una etiqueta especial anomenada *declaració XML*, que serveix per indicar que un document és XML.

```
1 <?xml version="1.0"?>
```

La declaració XML és opcional, tot i que es considera recomanable, ja que té alguns atributs que poden ajudar als programes a entendre característiques del document com el codi de caràcters que s'hi fa servir, la versió d'XML que s'ha usat, etc.

Si la declaració és present s'ha de tenir en compte que:

- La declaració ha d'estar en la primera línia del document i ha de començar en el primer caràcter del document.
- Ha de tenir obligatòriament l'atribut `version`, que actualment només pot ser `1.0` o `1.1`.

Per tant, la declaració següent és errònia perquè deixa una línia en blanc, deixa espais davant de la declaració i no defineix l'atribut `version`:

```
1 .
2   <?xml ?>
```

Com que la declaració és opcional podem trobar documents XML sense aquesta declaració. Si això passa els programes que llegeixin el document han de suposar que és tracta d'un document XML versió 1.0.

2.3.1 Atributs de la declaració XML

La declaració XML permet definir tres atributs (taula 2.4).

Taula 2.4. Atributs de la declaració XML

Atribut	Objectiu	Obligatori ?
version	Defineix quina versió d'XML s'ha fet servir per crear el document.	Sí

TAULA 2.4 (continuació)

Atribut	Objectiu	Obligatori ?
encoding	Defineix el codi de caràcters que fa servir el document.	No
standalone	Serveix per indicar si el document no depèn d'altres documents.	No

Atribut "version"

L'atribut `version` serveix per especificar mitjançant quina versió d'XML s'ha d'interpretar el document. Tot i que la definició XML és opcional, si hi és aquest atribut esdevé obligatòria.

Per tant, si es carrega el document següent en un programa li estem donant instruccions que ha de tractar el document segons les especificacions de la versió 1.1.

```
1 <?xml version="1.1" ?>
2 <nom>Pere Garcia</nom>
```

Si no s'especifica la definició o bé el valor és incorrecte els programes poden ignorar el que hi hagi i suposar que la versió és la 1.0. Per tant, els dos documents següents han de ser interpretats com a 1.0:

```
1 <?xml version="1.9" ?>
2 <nom>Pere Garcia</nom>
```

```
1 <nom>Pere Garcia</nom>
```

Atribut encoding

L'atribut `encoding` permet definir amb quin codi de caràcters s'han codificat les dades.

Per defecte tots els programes que llegeixin XML han de poder interpretar els codis de caràcters que estiguin en UTF-8 i UTF-16 i fins i tot detectar en quina de les dues codificacions està fet el document. Això implica que si el document està creat amb alguna d'aquestes codificacions no caldria especificar l'atribut `encoding`. Tot i això, per motius de llegibilitat del document sovint s'hi especifica igualment.

Com que l'estàndard ASCII és un subconjunt d'UTF-8 els documents que estiguin en ASCII tampoc no requereixen cap declaració.

En canvi, si el document segueix alguna altra codificació l'atribut s'ha d'especificar explícitament. Per un document creat fent servir el codi de caràcters ISO-8859-15 és obligatori tenir definit l'atribut que indiqui el codi de caràcters que s'ha fet servir:

```
1 <?xml version="1.0" encoding="ISO-8859-15"?>
```

Es poden fer servir les abreviacions de codis de caràcters de la taula 2.5.

Taula 2.5. abreviacions de codis de caràcters acceptades per l'XML

Tipus	Codis de caràcters
Unicode	UTF-8, UTF-16, ISO-10646-UCS-2, i ISO-10646-UCS-4
ASCII i variants	ISO-8859-1, ISO-8859-2, ..., ISO-8859-n
JIS X-0208-1997	ISO-2022-JP, Shitf_JIS, EUC-JP

Vegeu la definició de codificacions de l'IANA en la secció "Adreces d'interès" del web del mòdul.

Per a altres codis de caràcters es recomana fer servir els noms que defineix l'IANA (`http://www.iana.org/assignments/character-sets`).

Si a pesar d'això el codi de caràcters que es fa servir no està en la llista s'ha de fer començar el nom amb `x-`.

Atribut "standalone"

Els documents d'esquemes poden fer que algunes de les etiquetes les hagin de tractar de manera diferent els programes. Per exemple, definint atributs per defecte en algunes etiquetes i que, per tant, no cal que siguin específicament declarades en el document XML.

En la definició del vocabulari es pot definir que l'element `<persona>` té un atribut `versió` que per defecte és `home`. En crear el document es podria definir l'etiqueta sense especificar-ne l'atribut perquè el seu valor està implícit.

```
1 <persona>Joan</persona>
```

Si un programa tracta aquest document ha de tenir en compte aquest valor, i per tant haurà de llegir el document que declara els atributs per defecte.

Amb l'atribut `standalone` s'està definint si el document XML es pot entendre per si sol o bé necessita que sigui interpretat amb l'ajuda d'algun altre document, i per aquest motiu només té dos valors possibles (taula 2.6).

Taula 2.6. Valors possibles de l'atribut standalone

Valor	Significat
yes	El document és complet, i per tant no li calen altres documents per ser interpretat.
no	El document no es pot entendre per si sol i n'hem de llegir d'altres per poder-lo entendre.

Si l'atribut no s'especifica es considera que el valor de l'atribut `standalone` és **no**.

2.4 Correctesa

Els programes d'ordinador no tenen la flexibilitat que tenen els documents XML i necessiten poder treballar amb dades molt pautades, i precisament això és el que intenten fer les regles, evitar que hi hagi parts del document que puguin ser malinterpretades. Com que la majoria de les vegades els documents XML hauran de ser llegits per programes, és molt important tenir alguna manera de comprovar que aquest document XML estigui ben format, que compleixi les regles de definició de l'XML.

> Comprovar la correctesa d'un document XML és comprovar que no s'incompleix cap de les regles de definició d'XML.

Es considera que un document és correcte o ben format si compleix amb les regles bàsiques de creació d'un document XML. En general podem definir aquestes regles com:

- Només hi pot haver un element arrel.
- Totes les etiquetes que s'obren s'han de tancar.
- Les etiquetes han d'estar imbricades correctament.
- Els noms de les etiquetes han de ser correctes.
- Els valors dels atributs han d'estar entre cometes.

2.4.1 Només hi pot haver un element arrel

En l'exemple següent:

```
<persona>
   <nom>Pere</nom>
   <cognom>Garcia</cognom>
</persona>
```

L'etiqueta que surt en primer lloc, `<persona>`, i que acaba al final, `</persona>`, defineix el que s'anomena **element arrel**. Que un element sigui arrel vol dir que no té cap element que el contingui.

En aquest altre exemple, en canvi, hi ha dos elements arrel, `<persona>` i `<gos>`:

```
<persona>
   <nom>Pere Garcia</nom>
</persona>
<gos>
   <nom>Rufy</nom>
</gos>
```

Es pot veure que tant `<persona>` com `<gos>` no tenen cap element que els contingui i, per tant, tots dos són elements arrel. **Això fa que no sigui un document XML ben format**.

També hi ha dos elements arrel en el cas en què les etiquetes siguin les mateixes. Per exemple, en el document següent tenim dos elements arrel `<persona>`. Per aquest motiu, aquest document tampoc no està ben format.

```
<persona>
   <nom>Pere</nom>
   <cognom> Pérez </cognom>
</persona>
<persona>
   <nom>Marià</nom>
   <cognom>Garcia</cognom>
</persona>
```

Si es volgués convertir el document anterior en un document ben format es podria posar un element nou que englobés els dos elements arrel. Per exemple, s'hi s'afegeix un element `<persones>` i així es crea un document XML ben format:

```
<persones>
    <persona>
       <nom>Pere</nom>
       <cognom> Pérez </cognom>
    </persona>
    <persona>
        <nom>Marià</nom>
        <cognom>Garcia</cognom>
    </persona>
</persones>
```

2.4.2 Totes les etiquetes que s'obren s'han de tancar

A pesar del que passa en altres llenguatges de marques, per exemple HTML, en l'XML totes les etiquetes que s'obrin han de ser tancades obligatòriament. Per tant, aquest seria un exemple correcte:

```
<nom>Pere</nom>
```

Mentre que aquest no seria correcte:

```
<nom>Pere
```

En alguns moments pot caldre reflectir alguna dada que no requereixi cap valor. Per exemple si tenim una llista d'alumnes ens podria interessar marcar quin d'ells és el delegat. Per definir-ho no ens caldria cap dada, ja que simplement l'alumne que tingui l'etiqueta `<delegat>` és el delegat. Per tant, per definir que en Frederic Pi és el delegat podríem estar temptats de fer això:

```
<alumnes>
    <alumne>
        <nom>Pere Garcia</nom>
```

```
    </alumne>
    <alumne>
        <nom>Frederic Pi</nom>
        <delegat>
    </alumne>
    <alumne>
        <nom>Maria Puigdevall</nom>
    </alumne>
</alumnes>
```

Això és incorrecte. Si obrim una etiqueta l'hem de tancar; per tant, hauríem de fer:

```
...
<alumne>
   <nom>Frederic Pi</nom>
   <delegat></delegat>
</alumne>
...
```

O bé fer servir la versió de definició d'etiquetes buides acabant l'etiqueta amb "/>" :

```
...
<alumne>
    <nom>Frederic Pi</nom>
    <delegat/>
</alumne>
...
```

2.4.3 Les etiquetes han d'estar imbricades correctament

Per mantenir la jerarquia, l'XML defineix que les etiquetes no es poden tancar si encara hi ha alguna etiqueta que forma part del contingut que no ha estat tancada. Això és perquè no es permet que un element tingui una part del seu contingut en un element i una altra part en un altre, ja que això trencaria la jerarquia de dades.

Tancament de les etiquetes desordenat

Alguns llenguatges de marques sí que permeten obrir i tancar les etiquetes en qualsevol ordre. Per exemple, les versions anteriors a la 4.0 d'HTML permetien obrir i tancar etiquetes en l'ordre que volguéssim sempre que s'acabessin tancant totes. Però a partir de la versió 4.0 ja no s'accepta, a pesar que la majoria dels navegadors sí que ho permeten.

Per tant, sempre que s'obri una etiqueta dins d'un element aquesta ha de ser tancada abans d'acabar l'element. Aquest exemple seria correcte perquè l'element `<persona>` en el seu contingut obre l'etiqueta `<nom>` però abans d'acabar tanca `</nom>`:

```
<persona><nom>Pere</nom></persona>
```

En canvi, si les etiquetes no es tanquen en l'ordre correcte, encara que es compleixi la regla que s'han de tancar totes les etiquetes, no tenim un document XML ben format.

```
<persona><nom>Pere</persona></nom>
```

En l'exemple que acabem de veure s'està creant un bucle, ja que `<persona>` conté una part de `<nom>` i alhora `<nom>` conté una part de `<persona>`. Això trenca amb la idea de jerarquia de les dades que defineix l'XML i, per tant, no és correcte.

Per facilitar l'escriptura de documents XML i minimitzar els possibles errors per culpa de tancaments desordenats, els documents XML **sovint es representen sagnats**.

Sagnia

La sagnia consisteix a escriure les etiquetes de manera sagnada en funció del seu nivell dins de la jerarquia d'elements. A mesura que es van creant nous elements dins d'altres es van afegint sagnies.

En l'XML la sagnia es fa en funció del nivell en què es troben les dades. En general cada un dels fills fa que s'incrementi la sagnia. Per exemple:

```
<alumne>
    <persona>
        <nom>
        </nom>
    </persona>
</alumne>
```

Fent servir la sagnia és més fàcil determinar en quin lloc s'ha produït un error de tancament d'etiquetes i arreglar-ho. Com podem veure en l'exemple següent, si les etiquetes de tancament no estan en la mateixa columna que les d'obertura és que hi ha alguna cosa malament.

```
<institut>
    <classe>
        <alumne>Pere</alumne>
        <alumne>Joan</alumne>
    </institut>
</classe>
```

En general la sagnia aporta dos avantatges a l'XML:

1. Evita que es cometin errors a l'hora de tancar les etiquetes.
2. Fa que sigui més fàcil veure d'un cop d'ull l'estructura del document.

2.4.4 Els noms de les etiquetes i dels atributs han de ser correctes

Vegeu l'apartat "Noms vàlids XML" en aquest apartat.

L'XML dóna molta llibertat a l'hora de definir els noms dels elements i dels atributs però no tots els noms són acceptats.

En general tindrem que:

- No es poden posar noms que no comencin per un caràcter ni que continguin espais dins seu.
- Les majúscules i les minúscules són caràcters diferents per a XML.
- Els noms que comencin per `xml` estan reservats.

Per tant, seria incorrecte escriure una etiqueta en minúscules i després tancar-la en majúscules:

```
<persona>Pere</Persona>
```

Els noms han d'estar escrits de la mateixa manera:

```
<persona>Pere</persona>
```

No es poden posar etiquetes ni atributs que comencin per `xml` perquè estan reservats per l'estàndard.

En l'exemple següent hi ha un error en el nom de l'atribut `xmlpersona`:

```
<persona xmlpersona="si">Pere</persona>
```

De fet, ja hi ha alguns atributs començats per `xml` que s'accepten perquè estan definits en l'estàndard i tenen un objectiu clar: `xml:lang`, `xml:space`, `xmlns`...

2.4.5 Els valors dels atributs han d'estar entre cometes

En l'apartat de definició dels atributs ja es comenta que els valors dels atributs sempre han d'anar entre cometes però podem resumir el més important.

Vegeu l'apartat "Atributs" en aquest apartat.

No importa quines siguin les cometes que fem servir, dobles o simples, sempre que es facin servir les mateixes en obrir que en tancar.

```
<classe nom="Llenguatges de marques">
    <alumne delegat='si'>Pere Garcia</alumne>
    <alumne>Frederic Pi</alumne>
</classe>
```

Encara que el contingut dels atributs sigui un valor numèric s'ha d'especificar entre cometes:

```
<alumne nota="10">Maria Puigdevall</nom>
```

Podem especificar tants atributs com calgui en una etiqueta i l'ordre en què s'especifiquen no té importància:

```
<alumne nom="Pere" cognom="Garcia" nota="6" />
```

2.4.6 Processadors XML

L'objectiu principal de totes les regles que defineixen com s'ha d'escriure un document XML és definir una manera d'escriure documents XML que puguin ser llegits i interpretats per un programa d'ordinador. Els programes encarregats de detectar si un document XML està ben format s'anomenen genèricament **processadors d'XML**, tot i que sovint es fa servir el nom en anglès, ***parsers***.

Un processador d'XML és un programa que permet llegir un document XML i accedir-ne a l'estructura i a les dades que conté. Això ho fa llegint tot el document

i determinant quins dels caràcters que hi troba són part de l'estructura i quins són realment dades.

Vocabularis

XML permet definir etiquetes sense cap restricció però en canvi els programes només poden funcionar amb les etiquetes per les que han estat programats.

Per aquest motiu els programes defineixen quins conjunts d'etiquetes accepten. La llista d'etiquetes que s'accepten en un determinat llenguatge s'anomenen **vocabularis**.

Generalment es classifiquen els processadors en dos grans grups:

- **Processadors validadors**: comproven que els documents compleixen les regles i restriccions definides en l'esquema del vocabulari que se li ha associat i, per tant, a part de la lectura del document XML també han de llegir l'esquema contra el qual es valida.
- **Processadors no validadors**: revisen que el document no incompleix cap de les normes i regles de definició d'XML.

Sempre que no es tingui cap tipus de definició de vocabulari associada a un document XML es pot comprovar que el document és correcte amb un processador que no validi. En canvi, si tenim el vocabulari ens caldrà un processador validador que comprovarà que realment estem posant les etiquetes allà on poden anar.

Les tasques dels processadors XML es fan sempre **abans** que el programa que ha de treballar realment amb les dades faci res. Per tant, el procediment sempre serà: primer passar el document pel processador, i si el processador el dóna per correcte llavors es passa al programa (figura 2.1).

Figura 2.1. Pas d'un document XML a un programa

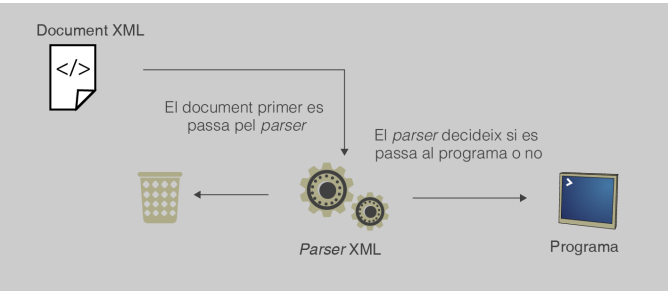

Errors

A part de definir com s'han de crear els fitxers XML l'especificació també defineix com han de reaccionar els processadors davant dels diferents errors que puguin detectar en tractar un fitxer XML. Els errors es defineixen en dos grups:

- **Errors lleus**: els errors lleus són els que incompleixen alguna de les regles definides com a *recomanacions*. Si algun document XML incompleix alguna recomanació l'analitzador pot continuar analitzant el document intentant recuperar-se de l'error.

- **Errors greus**: es generen quan s'incompleix alguna de les regles *obligatòries* de l'especificació. Es defineix que en cas de trobar algun error greu l'analitzador s'ha d'aturar immediatament i no continuar amb el procés d'anàlisi. En general qualsevol error que faci que el document no sigui "ben format" serà un error d'aquest tipus.

Navegadors web

Un cop s'ha creat un document XML normalment caldrà comprovar que aquest document està **ben format** segons les regles d'XML fent servir un processador XML.

La manera més senzilla de comprovar que un document està ben format és carregar-lo des d'un navegador. La majoria dels navegadors porten un processador XML incorporat i detecten automàticament que un document és XML i el comproven (figura 2.2).

Figura 2.2. Document correcte des d'un navegador

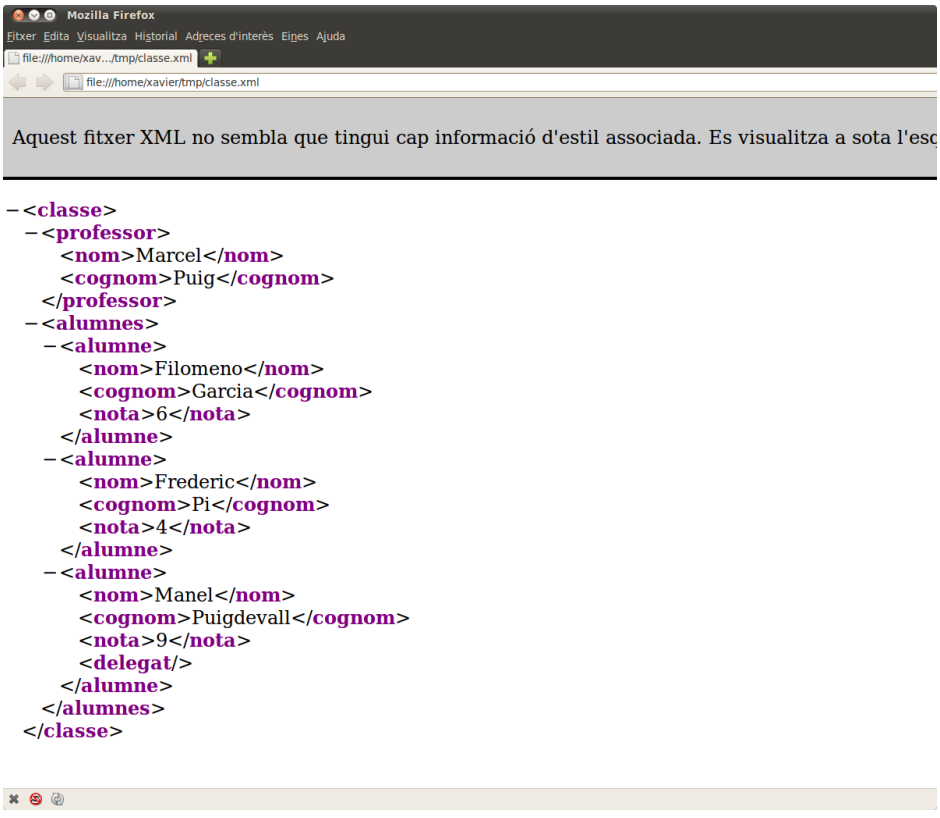

En cas de produir-se un error els navegadors mostren quin error s'hi ha produït i en quina línia es troba l'error (figura 2.3).

Figura 2.3. En carregar un document XML incorrecte en el navegador Google Chrome ens mostra els errors.

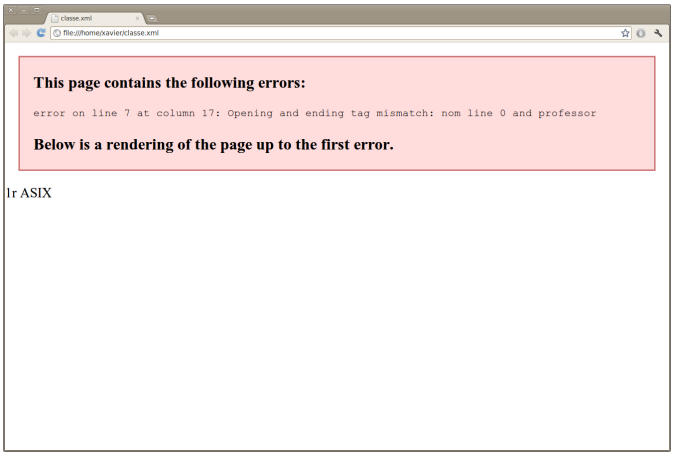

Processadors XML

En comptes de fer servir un navegador web per comprovar els documents XML sovint es fa servir un processador. La majoria dels processadors formen part de biblioteques que els programadors poden usar des dels seus programes per carregar els documents XML i comprovar-los.

A vegades els processadors porten utilitats que permetran comprovar ràpidament si un document està ben format o no sense haver de desenvolupar un programa per fer-ho.

Volem destacar els processadors següents:

- libxml2
- Apache Xerces
- Expat
- MSXML

libxml2

libxml2 forma part del projecte Gnome i és un processador de codi obert que està escrit en llenguatge C, però que es pot fer servir des de diferents llenguatges de programació com Perl, Ruby, Python, C#, PHP... i des de diferents sistemes operatius com Windows, Linux o Mac OS X. Està instal·lat per defecte en moltes de les distribucions de Linux.

Entre les utilitats que inclou n'hi ha una que funciona des de l'entorn d'ordres, anomenada **xmllint**, que és un analitzador i validador de documents XML.

Es pot comprovar si un document està ben format simplement especificant-lo com a paràmetre. Per validar el document següent:

```
1 <?xml version="1.0"?>
2 <persona>
3   <nom>Pere</nom>
```

```
</persona>
```

Executarem l'ordre:

```
$ xmllint persona.xml
```

Si el document és correcte mostrarà el document XML per pantalla (es pot evitar aquest comportament amb el paràmetre `-noout`):

```
$ xmllint persona.xml
<?xml version="1.0"?>
<persona>
  <nom>Pere</nom>
</persona>
```

En el cas que hi hagi algun error es mostrarà per pantalla i donarà informació sobre en quin lloc es troba i quin és l'error. Si modifiquem el document XML perquè tingui un error:

```
<persona>
    <nom>Pere
</persona>
```

Quan el passem a `xmllint`, aquest ens informarà que hi ha un error a la línia 3 perquè ha detectat que s'ha tancat `<persona>` però `<nom>` no està tancat.

```
$ xmllint persona.xml
persona.xml:3: parser error : Opening and ending tag mismatch: nom line 2 and
    persona
</persona>
          ^
persona.xml:4: parser error : Premature end of data in tag persona line 1
^
```

També es pot fer servir `xmllint` per veure que els processadors intenten arreglar els errors lleus que hi pugui haver en un document. Si eliminem la declaració XML del document (no estem provocant cap error, ja que la declaració només és una recomanació):

```
<persona>
    <nom>Pere</nom>
</persona>
```

En passar-lo per xmllint es pot veure que ha detectat que la declaració no hi era i l'ha afegida automàticament:

```
$ xmllint  persona.xml
<?xml version="1.0"?>
<persona>
    <nom>Pere</nom>
</persona>
```

Apache Xerces

Sota el nom de Xerces la fundació Apache manté un projecte de desenvolupament de processadors XML per a Java, C++ i Perl. Es tracta d'una de les biblioteques més usades per processar XML.

Expat

XML Parser Toolkit són unes biblioteques per fer servir XML des del llenguatge de programació C i Perl.

El fan servir alguns dels programes d'ús comú, com per exemple el servidor web Apache HTTP Server, el navegador Mozilla i les biblioteques dels llenguatges de programació Perl, Python i PHP.

Per exemple, en l'Ubuntu, en instal·lar la biblioteca, també s'instal·la un programa anomenat *xmlwf* que permet comprovar si un document està ben format des de la línia d'ordres. Si no diu res el fitxer està ben format.

```
$ xmlwf persona.xml
```

En cas d'error mostrarà en quina línia i columna es troba:

```
$ xmlwf persona.xml
persona.xml:3:2: mismatched tag
```

MSXML

Microsoft XML Parser és la biblioteca oficial per processar XML en molts dels productes de Microsoft. Es tracta d'una biblioteca inclosa en el sistema operatiu, i per tant s'actualitza via Windows Update. N'han anat sortint versions en què s'han anat afegint funcions. Es pot fer servir des de diferents llenguatges de programació, llenguatges de *scripts* o des de llenguatges basats en .NET

Fan servir MSXML productes com Microsoft Windows, Microsoft Office, Microsoft SQL Server, Microsoft Internet Explorer...

Molts dels programes que processen XML en sistemes Windows solen fer servir aquesta biblioteca (especialment si treballen en .NET).

Com que Internet Explorer fa servir aquesta biblioteca, simplement carregant un document XML amb Internet Explorer en realitat s'està comprovant amb l'MSXML (figura 2.4).

Figura 2.4. L'Internet Explorer ens permet comprovar documents amb l'MSXML

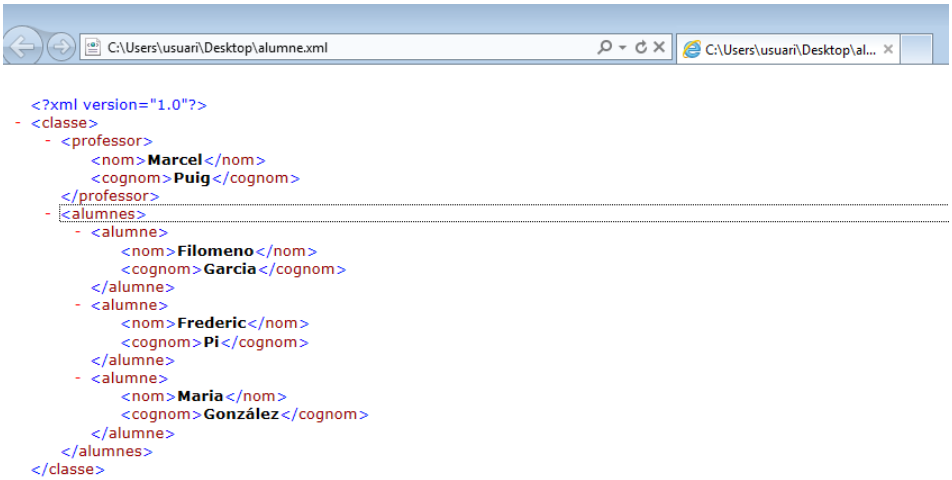

2.5 Estructura dels documents XML

Una de les coses que s'aconsegueixen en forçar que els documents XML segueixin les seves normes és fer que la informació que conté un document s'organitzi de manera jeràrquica.

Per exemple, tenim el document XML següent:

```
<?xml versión="1.0" encoding="UTF-8" ?>
<classe>
   <professor>
       <nom>Marcel</nom>
       <cognom>Puig</cognom>
   </professor>
   <alumnes>
       <alumne>
           <nom>Filomeno</nom>
           <cognom>Garcia</cognom>
       </alumne>
       <alumne>
           <nom>Frederic</nom>
           <cognom>Pi</cognom>
       </alumne>
       <alumne>
           <nom>Manel</nom>
           <cognom>Puigdevall</cognom>
           <delegat/>
       </alumne>
   </alumnes>
</classe>
```

Gràcies al fet que les etiquetes tenen noms clars es pot deduir que en aquest document XML s'estan definint estructuradament una classe amb un professor i tres alumnes. Hi ha un element arrel anomenat `<classe>` que engloba tot el document, i com a contingut té dos elements més, `<professor>` i `<alumnes>`.

> Els elements que formen part del contingut d'un node s'anomenen fills.

Per tant, `<classe>` té dos elements **fills**: `<professor>` i `<alumnes>`. Alhora l'element `<professor>`, que és un dels fills de `<classe>`, també té dos fills: `<nom>` i `<cognom>`.

```
...
    <professor>
        <nom>
            Marcel
        </nom>
        <cognom>
            Puig
        </cognom>
    </professor>
...
```

Per equivalència amb les relacions humanes els fills dels fills d'un element s'anomenen **néts**. Per tant, `<nom>` i `<cognom>` són fills de `<professor>` i **néts** de `classe`:

classe -> professor -> nom Els elements <nom> i <cognom> no tenen nodes fills sinó que contenen les dades del document. En aquest cas dues cadenes de text `Marcel` i `Puig`. Els nodes finals s'anomenen **fulles** i generalment seran sempre nodes de dades.

Es pot fer amb l'altre element fill de <classe>, però amb la diferència que té un nivell més. Ara es té una estructura més llarga:

classe -> alumnes -> alumne -> nom Tots els elements que pengen d'un element s'anomenen genèricament **descendents**. Per tant, <alumnes>, <alumne> i <nom> són descendents de <classe>.

Com podeu veure, és relativament senzill interpretar quines són les dades que conté un document XML, gràcies al fet que es fan servir noms d'etiqueta que tenen sentit per a un possible lector, però també es pot deduir quina és l'estructura de les dades i les relacions que tindran aquestes dades entre si.

El fet de seguir aquest sistema, que és flexible en determinats moments, però estricte en d'altres, ens permet fer que un programa d'ordinador també pugui de manera senzilla detectar ràpidament quina part del document són dades i quina són metadades, però que a més pugui establir quina és la relació entre aquestes dades.

En cap moment no s'ha especificat res sobre de quina manera s'hauran de representar les dades, ja que aquesta és una de les bases fonamentals del llenguatge XML:

> L'objectiu de l'XML és representar l'estructura de les dades oblidant-se de com es farà per presentar-les.

2.5.1 Representació en forma d'arbre

Una de les característiques interessants dels documents XML és que, en tenir les dades estructurades de manera jeràrquica, aquesta jerarquia fa que els documents XML puguin ser representats gràficament en forma d'arbre. La representació en arbre és útil per comprendre millor quina és l'estructura del document.

Per fer la representació en forma d'arbre sempre es parteix del node arrel, que en aquest cas és `classe` (figura 2.5).

Figura 2.5. Es comença definint l'element arrel com un node

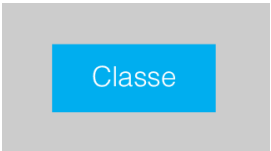

A partir del node arrel s'agafen els fills directes que tingui i s'enllacen amb un arc, que serà el que indicarà la relació que tenen els elements entre ells (figura 2.6).

Figura 2.6. S'hi afegeixen els fills

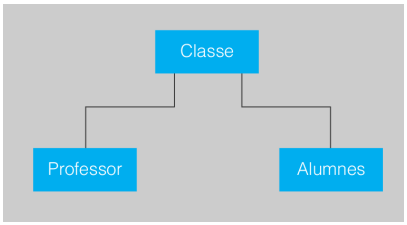

El mateix es pot fer per als fills de cada un dels nodes. Per exemple, `professor` té dos fills més, que són `nom` i `cognom`, que s'uniran a `professor` amb un arc per indicar que tenen relació pare/fill (figura 2.7). De fet, es fa és més o menys el mateix que es faria per crear un arbre genealògic.

Figura 2.7. I es va fent el mateix amb els fills de cada node

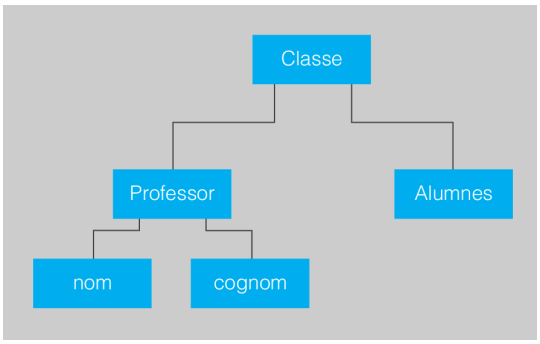

Com que ja no hi ha més elements per representar ja es poden pintar els nodes de dades, que generalment s'acostumen a pintar de color diferent (figura 2.8).

Figura 2.8. Els nodes de dades se solen representar d'una manera especial

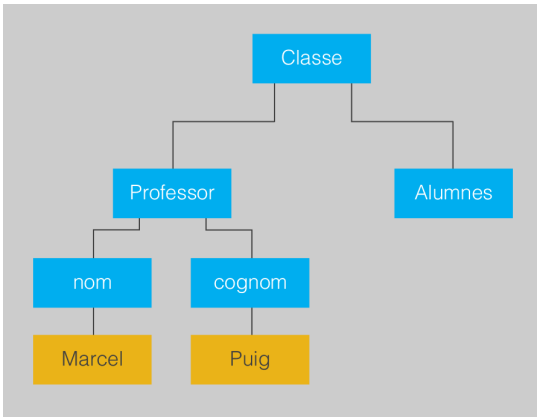

Si se segueix amb el document el resultat serà un arbre que ens representarà gràficament la relació que tenen els elements entre si (figura 2.9).

Figura 2.9. El resultat és la representació del document en forma d'arbre

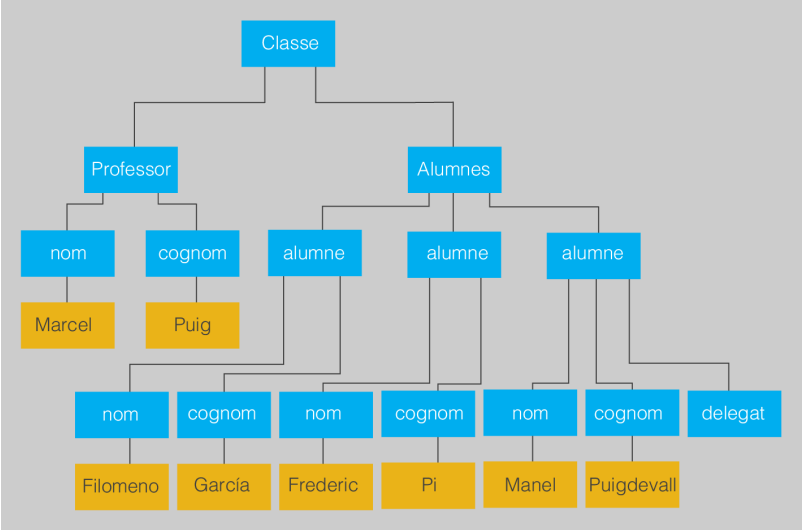

2.5.2 Representació en els navegadors

Una representació semblant a la de l'arbre és la que han triat els navegadors per mostrar els documents XML si no els diem el contrari afegint-hi algun full d'estil. Quan s'obre un document XML en un navegador automàticament és representa sagnat i s'hi afegeixen nodes davant dels elements pares que permetran mostrar o ocultar els fills que conté (figura 2.10).

Figura 2.10. Representació d'un document XML correcte en el navegador Mozilla Firefox

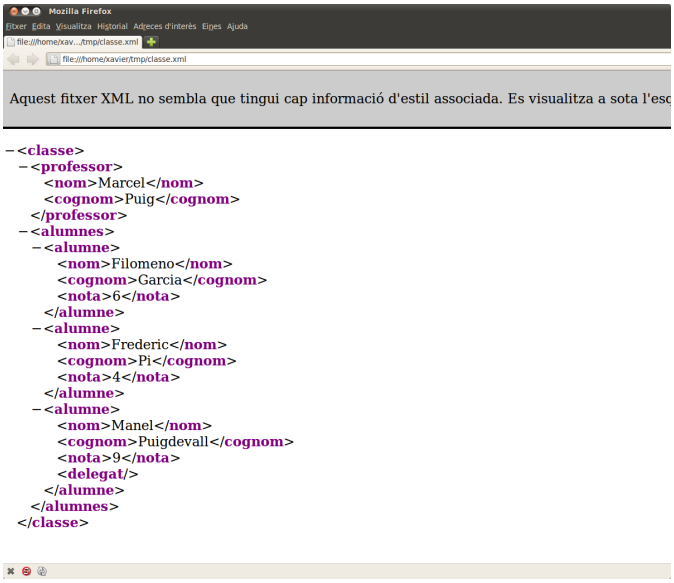

En la vista d'arbre que ofereixen els navegadors normalment es poden plegar i desplegar els fills dels nodes per poder personalitzar la visió del document (figura 2.11).

FIGURA 2.11. El Firefox permet plegar i desplegar els fills dels nodes

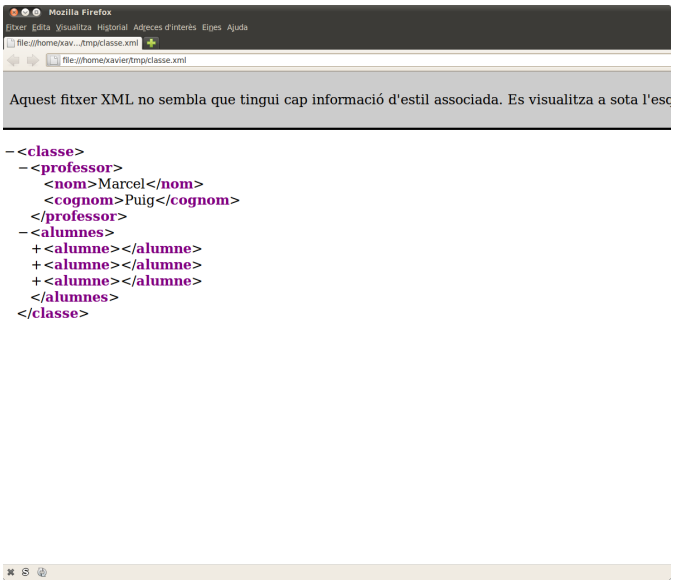

2.6 Creació de documents XML

Generalment els documents XML seran creats i llegits des de programes d'ordinador, però algunes vegades també es pot donar el cas que s'hagin de crear manualment.

Crear un document XML manualment és molt més senzill que crear un document binari, ja que no difereix gaire de crear un document de text. Simplement necessitem un editor de text que no enriqueixi el text.

2.6.1 Editors

Els documents XML són simples documents de text en què hem afegit algun tipus de metadades. Això permet que la creació de documents XML sigui realment senzilla, ja que es pot fer servir l'editor més senzill que trobem en qualsevol sistema operatiu per poder crear els nostres documents.

A pesar d'això també han aparegut tota una sèrie d'editors pensats per fer l'edició de documents XML més senzilla. Aquests editors són molt diversos i normalment ofereixen diferents tipus d'assistència per evitar que es cometin errors en crear el document: comprovar interactivament que el document sigui correcte, aconsellar etiquetes, acolorir...

Molts dels editors especialitzats en XML normalment a més ofereixen moltes altres funcions com generació d'expressions XPath, creació de fulls d'estil, depurament de transformacions, peticions XQuery...

Editors de text

L'única cosa que cal per crear un document XML és un editor de text normal i corrent que no enriqueixi el text. Els documents de text que permeten afegir format, com ara text en negreta, canviar el tipus de lletra, etc., com per exemple el Microsoft Word, l'OpenOffice.org Writer, el LibreOffice Writer, etc., solen generar documents de text enriquit que es concentren més en com s'ha de mostrar el document que no pas en les dades. A més, aquests programes sovint canvien automàticament alguns caràcters del text que anem escrivint (les cometes solen ser canviades sistemàticament) per fer-lo més "agradable" a l'hora d'imprimir-lo, com es pot veure a la figura 2.12.

Figura 2.12. L'OpenOffice.org modifica les cometes per fer-les més "agradables" a la vista

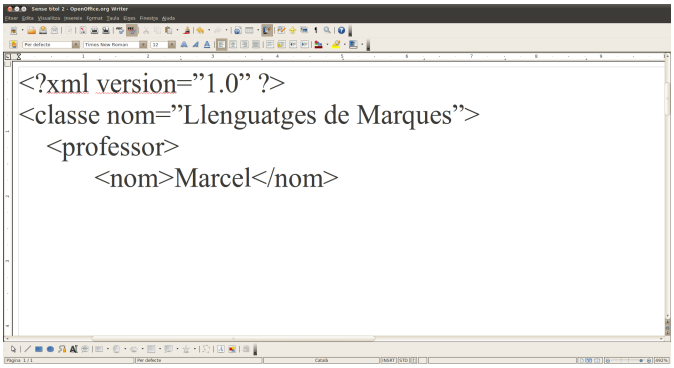

Per tant, aquests programes no són els més adequats per crear documents XML, tot i que és possible fer-ho si a l'hora de desar els documents es va amb compte d'especificar que es volen desar com a "text" (figura 2.13).

Figura 2.13. Es pot fer servir l'OpenOffice.org però anant en compte a l'hora de desar el document

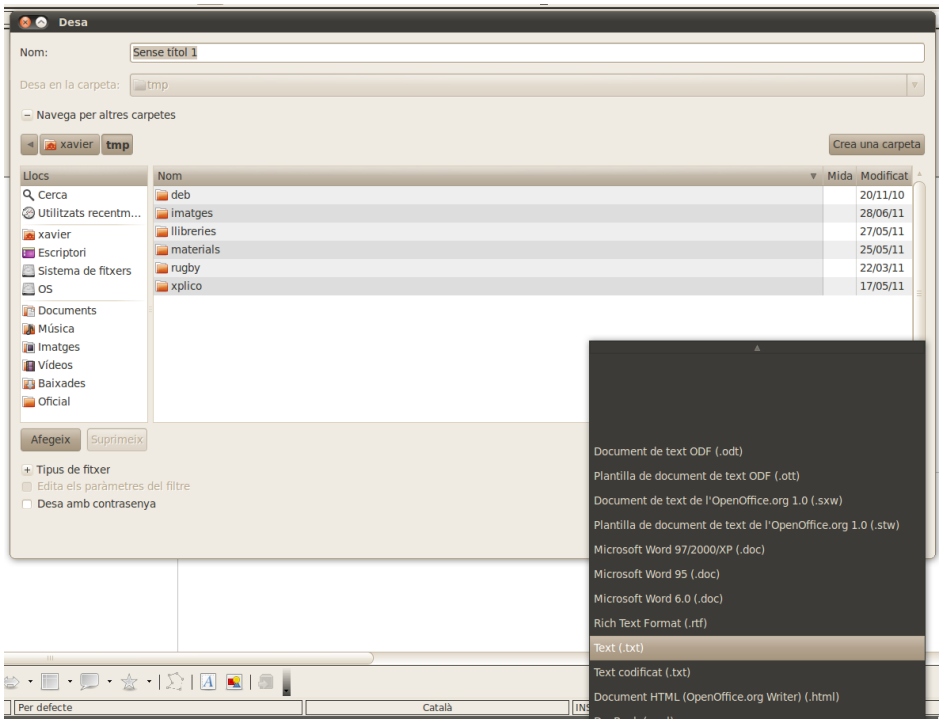

La realitat és que per crear documents XML van molt millor els editors més senzills (Gedit, Bloc de notes, *vi*, etc.) que no pas els editors de text enriquit.

En alguns casos aquests editors més senzills fins i tot detecten que s'està editant un document XML i marquen amb colors diferents les etiquetes i les dades (figura 2.14).

Figura 2.14. L'editor Gedit de Gnome fins i tot ofereix acoloriment de text en els fitxers XML

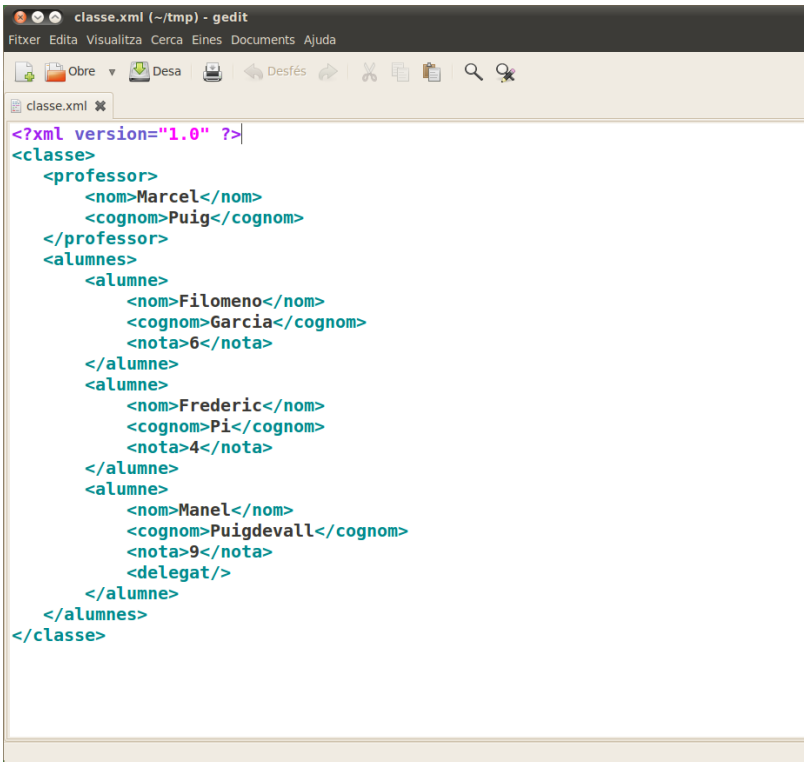

Editors amb suport d'XML

També hi ha un segon grup d'editors que, tot i no estar especialitzats en XML, hi poden tenir suport. Aquests editors normalment ofereixen una assistència mínima en editar XML, com acoloriment de les diferents seccions, comprovació automàtica del tancament de les etiquetes, o fins i tot se'n poden trobar amb autocompletament d'etiquetes.

Aquest comportament és típic dels editors pensats per ser usats pels programadors, com per exemple el Komodo IDE (figura 2.15), l'Eclipse o el Visual Studio.

L'èxit d'XML ha fet que alguns editors hagin incrementat el seu suport per a XML. Per exemple, les noves versions del Microsoft Visual Studio a més de l'autocompletament d'etiquetes permeten definir esquemes i depurar transformacions des de l'entorn integrat (figura 2.16).

Figura 2.15. Molts dels editors dels entorns de programació ofereixen suport als documents XML. Per exemple, l'editor de codi obert Komodo

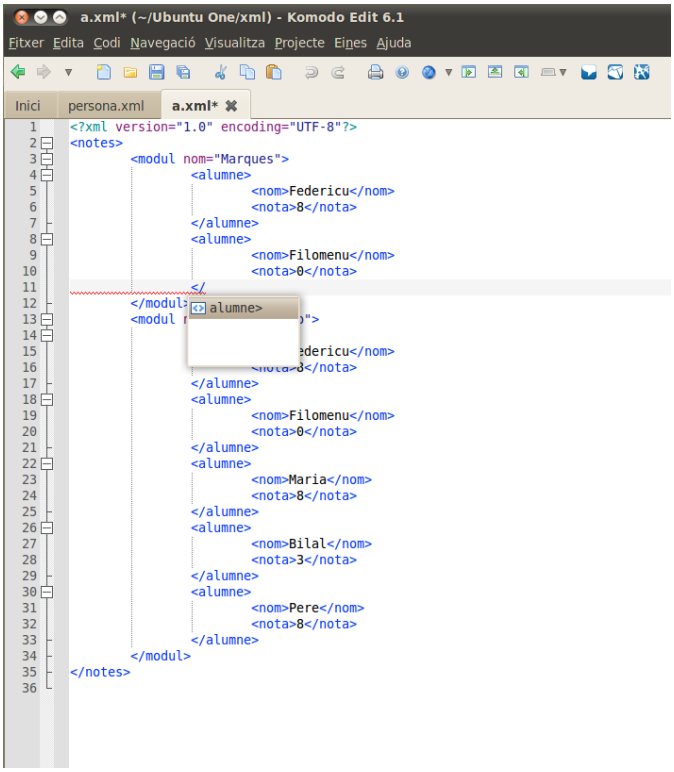

Figura 2.16. Microsoft ha afegit al Visual Studio suport per a diverses tecnologies XML

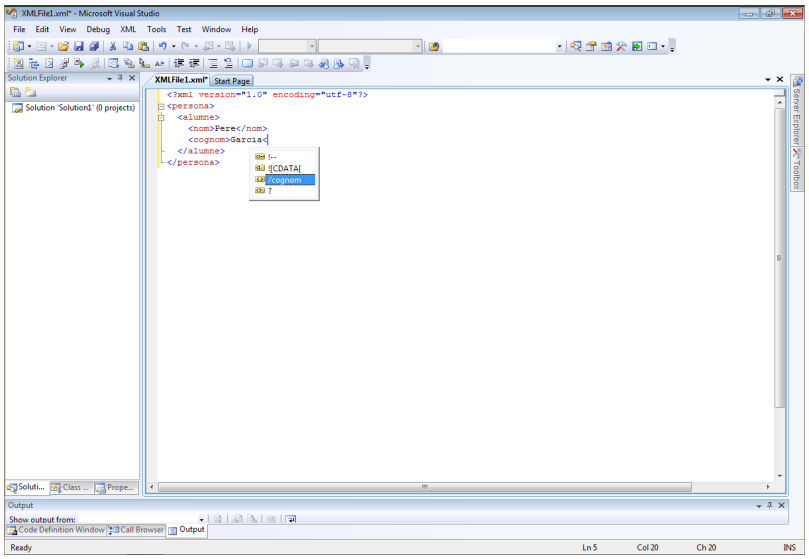

Editors especialitzats en XML

Tot i que amb els altres editors es poden crear documents XML, quan es vol fer un treball professional normalment s'ha d'acabar recorrent a un editor d'XML. Aquests editors estan dissenyats específicament per crear i editar documents XML de manera eficient i senzilla minimitzant les possibilitats que es cometin errors en l'edició. Generalment tots ofereixen un entorn amb un grup de finestres amb diferents vistes de l'edició per intentar que no es perdi la visió de conjunt del que s'està creant (figura 2.17).

Figura 2.17. L'editor EditiX ens va creant l'arbre XML alhora que anem escrivint el document XML

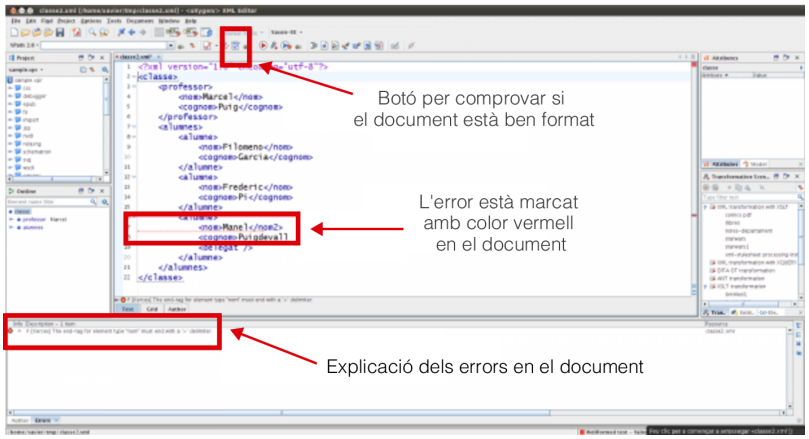

A part de la simple edició de documents XML, aquests editors permeten tot un ampli ventall de tasques amb les tecnologies relacionades amb l'XML com editar documents XML restringint les etiquetes que s'hi fan servir; definir un esquema; crear, convertir i depurar esquemes XML, XSLT, XPath, XQuery, WSDL, SOAP... També ofereixen ajudes per crear documents en vocabularis basats en XML, etc.

Una característica interessant que ofereixen és la possibilitat d'editar documents XML des de diferents punts de vista. El més corrent sol ser fer-ho per mitjà de vistes de text o diferents vistes gràfiques destinades a amagar la complexitat dels documents XML als usuaris que fan servir l'editor.

L'edició en la **vista de text** (figura 2.18) no sol diferir gaire de l'edició en un editor normal i corrent però sol oferir alguns avantatges afegits com autocompletament d'etiquetes, acoloriment del contingut, finestres d'ajuda que mostren l'estructura del document, etc.

Figura 2.18. La vista de text és la ideal per editar els arxius veient clarament el format XML

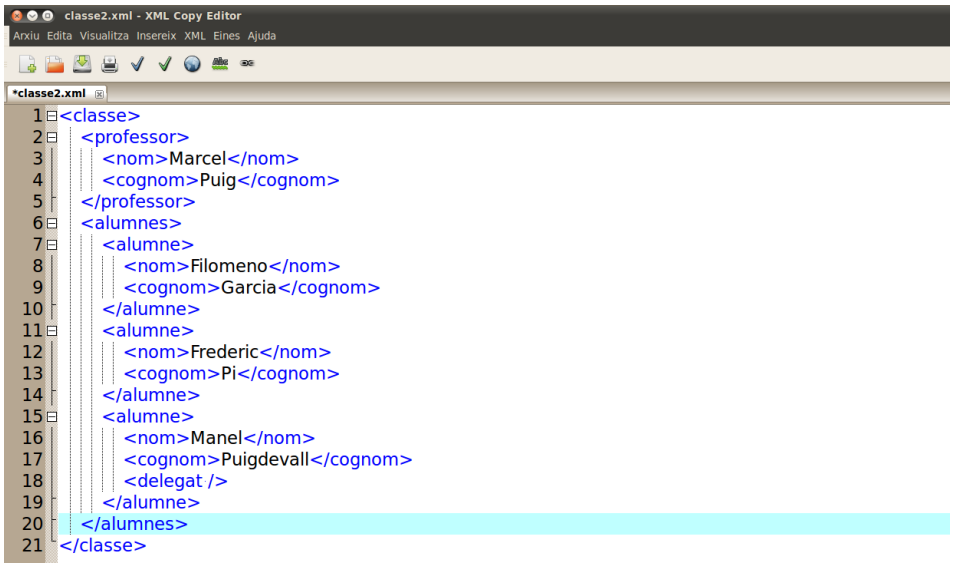

A part de l'edició de text molts editors també ofereixen vistes que permeten que un usuari pugui crear dades estructurades de manera gràfica sense que l'usuari ni tant

sols sàpiga que està creant un document XML. Una d'aquestes vistes alternatives és la **vista d'arbre** (figura 2.17). La vista d'arbre permet editar el document visualment a partir de l'estructura jeràrquica, de manera que no cal que el que està creant l'arbre conegui la sintaxi XML. Mentre l'usuari va creant l'arbre, l'editor en segon pla va creant el document XML corresponent (figura 2.19 i figura 2.20).

Figura 2.19. L'usuari va creant les dades de manera estructurada i l'editor crea el document XML per ell

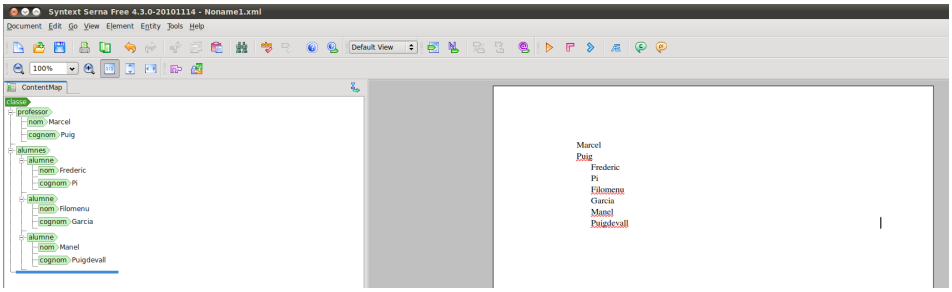

Figura 2.20. La vista d'arbre està pensada per als usuaris que no coneixen el llenguatge XML

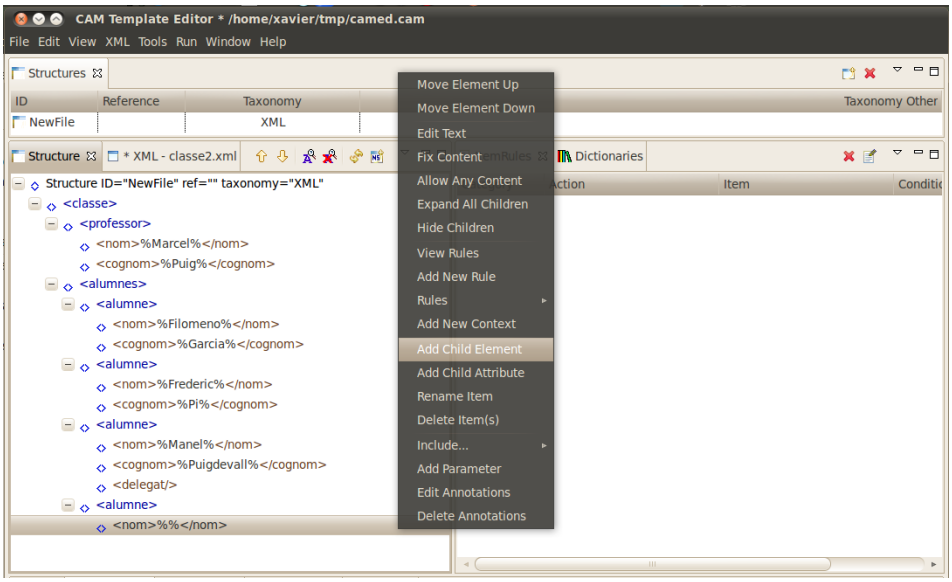

Amb la mateixa idea de fer que l'edició dels documents XML sigui més fàcil per als usuaris no especialitzats, també hi ha la **vista de graella** (figura 2.21).

Figura 2.21. Vista de graella

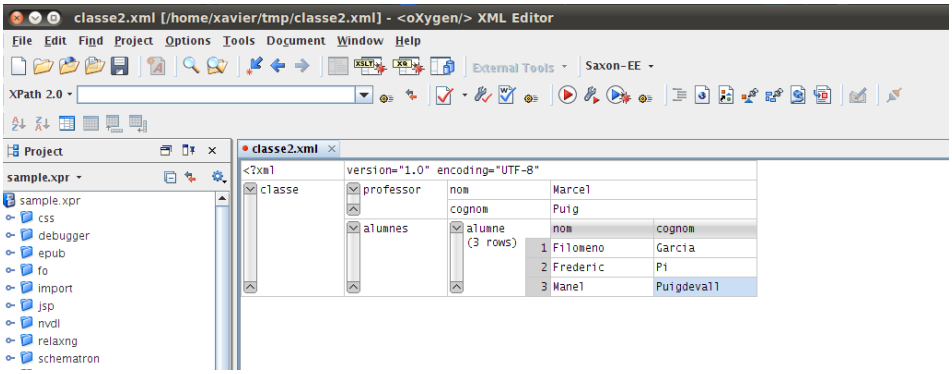

La vista de graella està pensada per a usuaris que només es volen preocupar de l'estructura del document i no de com crear-lo.

La popularitat del format XML està fent que el nombre d'editors especialitzats no pari de créixer i que per tant es faci difícil triar l'editor que s'adapta més bé a les necessitats que un usuari pugui tenir. Afortunadament la majoria dels editors comercials ofereixen un temps de prova abans d'obligar a comprar el programa, i per tant es poden provar diferents editors abans de decidir quin és el que s'adapta millor a les necessitats que tenim. A més, alguns editors tenen versions limitades gratuïtes o de codi obert que en molts casos poden ser suficients per satisfer les necessitats que es puguin tenir.

Entre els editors comercials normalment es destaquen aquests:

- **oXygen XML Editor** (Windows, Linux, Mac OS X)
- **Editix XML Editor** (Windows, Linux, Mac OS X)
- **Altova XMLSpy XML editor** (Windows)
- **Stylus Studio** (Windows)
- **XMLmind** (Windows, Linux, Mac OS X)
- **XMLwriter** (Windows)
- **Liquid XML Studio** (Windows)
- **Serna Enterprise XML Document Editor** (Windows, Linux, Mac OS X, Solaris)

També n'hi ha algun de codi obert però sovint les seves prestacions solen ser molt inferiors:

- **Serna Free Open Source XML Editor** (Windows, Linux, Mac OS X, Solaris)
- **XML Copy Editor** (Linux)

A pesar que en l'exemple es fa servir l'oXygen, la majoria dels editors funcionen d'una manera similar.

Edició d'un document amb un editor d'XML

Si bé és cert que podem crear un document XML amb un editor de text senzill, en aquest exemple es farà servir un editor especialitzat per veure'n les possibilitats. L'editor que farem servir per fer l'exemple és l'oXygen XML Editor.

Generalment els editors d'XML divideixen l'espai de treball en finestres en les quals cada una té una funció específica (figura 2.22).

Figura 2.22. Pantalla inicial de l'oXygen XML Editor, on es veuen els diferents espais

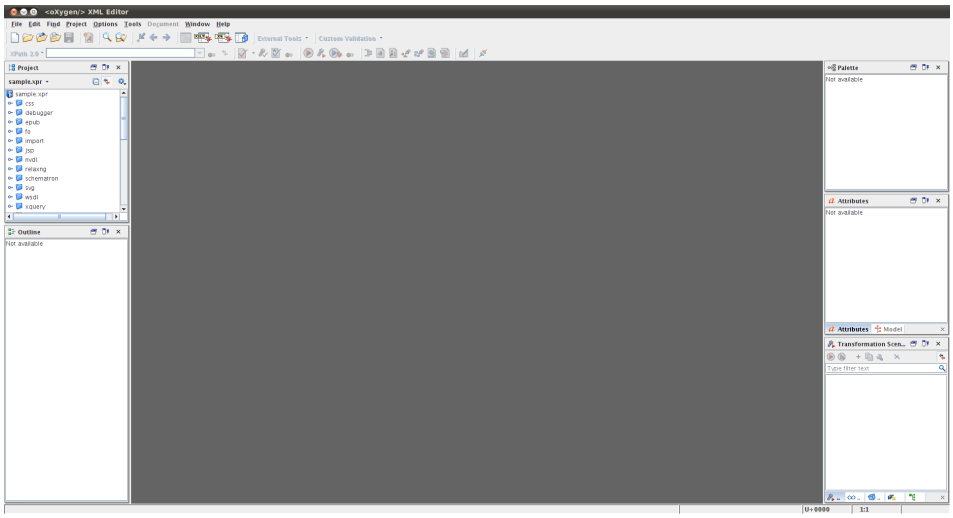

A l'hora de crear un fitxer nou els editors d'XML normalment obren un assistent (figura 2.23) que permet crear fitxers de diversos tipus, de manera que un cop se n'ha triat un se li afegiran automàticament les opcions predeterminades del tipus de document triat.

Figura 2.23. Assistent de creació d'arxius de l'oXygen

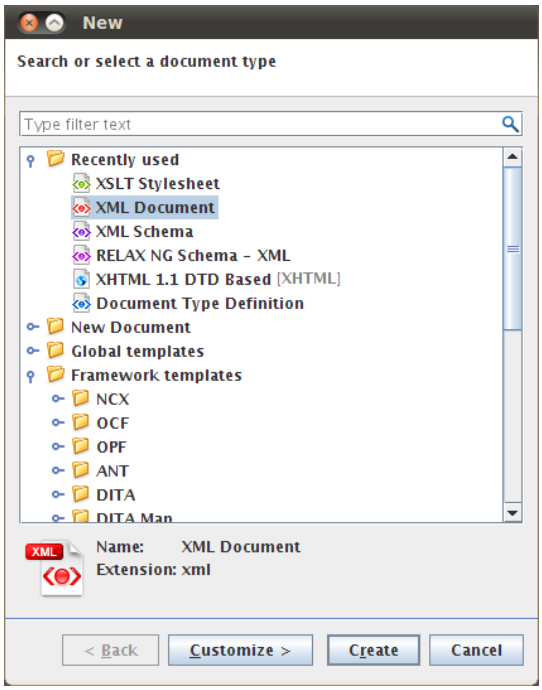

En crear un document XML s'afegeix la capçalera XML automàticament (figura 2.24).

Figura 2.24. Document XML creat per l'assistent d'oXygen

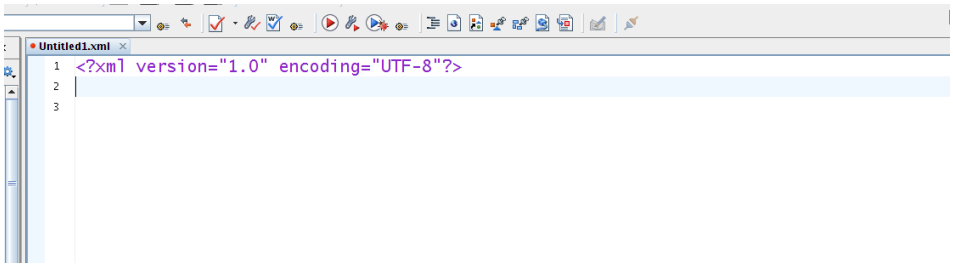

En editar, un assistent anirà oferint les possibilitats que consideri adients en cada punt concret (figura 2.25).

Figura 2.25. L'assistent d'edició ens indicarà què podem escriure en cada punt del document

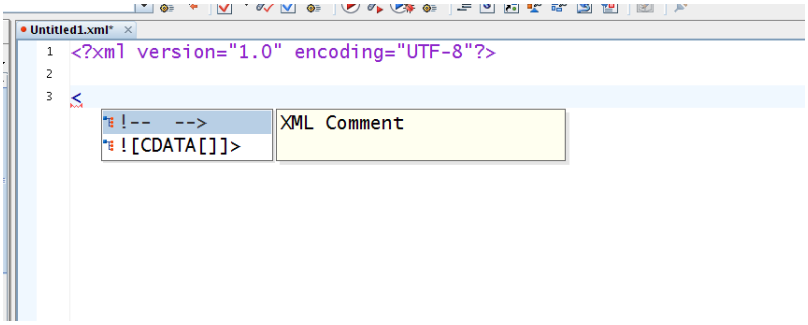

L'edició no té secrets, ja que el que es fa és simplement editar un arxiu de text amb un assistent que ofereix ajudes diverses:

- En crear una etiqueta d'obertura es crearà l'etiqueta de tancament.
- Mentre s'edita es van comprovant automàticament els errors que sorgeixin.
- Hi sol haver alguna manera de comprovar si un document està ben format, i un panell en el qual es poden veure els errors (figura 2.26).

Figura 2.26. Els errors en l'edició

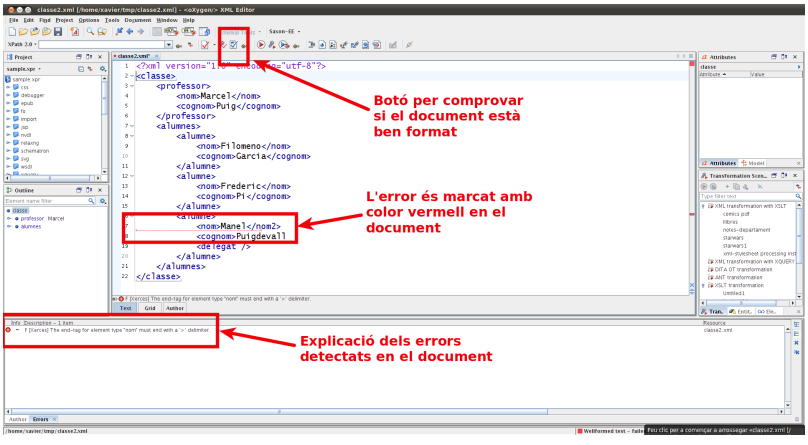

Els errors en l'edició són detectats per l'editor en escriure o bé quan li demanem que comprovi si el document està ben format.

2.6.2 Creació d'un document XML

A l'hora de definir un grup de dades dins d'un document XML caldrà fer tota una sèrie de passes prèvies que permetin determinar quines són les dades que cal emmagatzemar i posteriorment definir quina és l'estructura que s'ha de donar a aquestes dades; així doncs:

1. Determinació de les dades
2. Determinació de l'estructura

Determinació de les dades

És bàsic abans de crear un document XML saber clarament quines són les dades que s'hi han de posar. Sovint això estarà determinat pel programa que les ha de processar posteriorment, però també pot ser que el programa encara no existeixi i per tant la creació estigui determinada per les preferències personals, etc.

Si no s'està restringit per un programa que ja determini l'estructura del document XML, el que cal és determinar quines dades s'han d'emmagatzemar. Hi ha molts sistemes per fer-ho però el més senzill és fer una llista amb totes les dades rellevants.

Document XML per desar les dades d'una biblioteca

Volem crear una biblioteca en què es puguin emmagatzemar les dades dels llibres que hi ha. Per tant, fem una llista amb les dades que considerem que cal que hi hagi en el document:

- Títol
- Subtítol
- Autor
- Any de publicació
- Editorial
- Nom de la col·lecció
- Idioma

Determinació de l'estructura

Una altra de les coses bàsiques a l'hora de crear un document XML és definir quina és l'estructura que hauran de tenir les dades. Aquesta estructura estarà determinada per les necessitats del programa o de la persona que farà servir el document XML. De manera que les possibilitats a l'hora de crear una estructura per a les dades que volem fer servir són moltes: agrupar per autor, agrupar per llibre, agrupar per editorial, agrupar per tema...

Tria de l'estructura

En una biblioteca podem fer l'estructura des de molts punts de vista. Per exemple, la podem fer a partir dels autors, com aquesta:

- autor 1
  - llibre 1
  - llibre 2
- autor 2
  - llibre 1
- etc.

O bé podem la fer a partir dels llibres d'aquesta manera:

- llibre 1
  - autor 1
- llibre 2
  - autor 1
- etc.

La primera opció és la que s'ha triat per desenvolupar en aquest exemple.

Creació del document

Com que s'ha triat una forma d'organització per mitjà dels autors el que queda clar és que el primer nivell serà una llista d'elements `autor` més o menys d'aquesta manera:

```
<biblioteca>
    <autor></autor>
    <autor></autor>
    <autor></autor>
    ...
</biblioteca>
```

Dins de cada un dels autors les dades per emmagatzemar seran les dades personals de l'autor (el nom, en el nostre exemple) i la llista dels llibres de l'autor que hi hagi a la biblioteca:

```
<autor>
   <nom>Nom de l'autor</nom>
   <llibres>
       Llista de llibres
   </llibres>
</autor>
```

En el darrer nivell es poden posar totes les dades del llibre obviant les que ja estan implícites perquè estan en etiquetes superiors. En l'exemple, l'autor ja queda implícit i, per tant, no cal tornar-lo a posar:

```
<llibre>
    <titol>Titol del llibre</titol>
    <subtitol>Subtítol</subtitol>
    <any>Any en què s'ha publicat el llibre</any>
    <idioma>Idioma en què està escrit</idioma>
    <editorial>
        <nom>Nom de l'editorial</nom>
        <·collecció>Adreça de l'editorial</·collecció>
    </editorial>
</llibre>
```

En qualsevol moment es poden crear nivells nous per agrupar les dades segons algun sentit que interessi marcar. Per exemple, això és el que s'ha fet amb l'editorial.

Cal tenir en compte que no cal preocupar-se gaire que en alguns casos les dades no tinguin sentit o no existeixin, ja que en crear el document simplement es poden eliminar les etiquetes que no tinguin sentit.

Per tant, el document final podria quedar d'aquesta manera:

```
<bibloteca>
    <autor>
        <nom>John Ronald Reuel Tolkien </nom>
        <llibres>
          <llibre>
              <titol>El Hòbbit</titol>
              <any>2010</any>
              <idioma>català</idioma>
              <editorial>
                  <nom>Edicions de la magrana</nom>
                  <·collecció>L'Esparver</·collecció>
              </editorial>
          </llibre>
          <llibre>
              <titol>El senyor dels anells</titol>
              <subtitol>La germandat de l'anell</subtitol>
              <any>2002</any>
              <idioma>català</idioma>
              <editorial>
                  <nom>Editorial Vicens Vives</nom>
              </editorial>
          </llibre>
        </llibres>
    </autor>
    <autor>
        <nom>Isaac Asimov</nom>
        <llibres>
              <titol>Jo, robot</titol>
              <any>2001</any>
              <idioma>català</idioma>
              <editorial>
                  <nom>Edicions Proa</nom>
                  <·collecció>Proa Butxaca</nom>
              </editorial>
        </llibre>
    </autor>
</biblioteca>
```

2.7 Espais de noms

Amb l'XML es poden crear les etiquetes amb el nom que es vulgui en el moment en què calguin. Per tant, si tenim un document XML en el qual s'especifiquen habitacions de lloguer podríem tenir un document com aquest:

```
<lloguer>
    <adreça>
        <carrer>Escudillers, 23</carrer>
        <ciutat>Figueres</ciutat>
        <codi_postal>17600</codi_postal>
    </adreça>
    <habitacio>
        <rect>
            <finestres>2<finestres>
            <portes>1</portes>
        </rect>
    </habitacio>
<lloguer>
```

O sigui, en el darrer document XML estem especificant que hi ha una habitació de lloguer al carrer Escudillers, 23, de Figueres, que té forma rectangular amb dues finestres i una porta.

Tot i que teòricament el sistema sembla perfecte, en la pràctica té el problema que **el llenguatge humà és limitat** i a més moltes vegades hi ha paraules amb diversos sentits. Això fa que molta gent pugui triar les mateixes etiquetes per fer coses que siguin totalment diferents. Això d'entrada no és un problema fins que cal mesclar documents que vénen de fonts diferents.

En XML hi ha un llenguatge estàndard que serveix per representar gràfics 2D anomenat *SVG* (*scalable vector gràfics*). SVG serveix per definir gràfics vectorials, o sigui, que en comptes de desar els punts que formen les imatges es desa com s'han de dibuixar els gràfics fent servir figures geomètriques. Es poden veure alguns dels elements de SVG a la taula 2.7.

Taula 2.7. Etiquetes bàsiques del format SVG per representar gràfics vectorials

Etiqueta	Ús
svg	L'arrel dels documents SVG.
line	Serveix per definir línies d'un punt a un altre.
rect	Es fa servir per definir rectangles a partir de quatre punts.
circle	Amb aquesta etiqueta es defineixen cercles a partir del punt central i el radi.
ellipse	Ens permet definir el·lipses a partir del punt central i els dos radis.
polygon	Permet dibuixar polígons a partir d'un grup de punts.

Per tant, algú podria decidir que el document milloraria si s'hi afegeix una representació gràfica de la planta dels pisos, i que es pot aprofitar el llenguatge SVG per fer-la.

Com que l'XML permet mesclar diferents vocabularis, simplement s'hi afegeix. Per fer-ho més estructurat, a més, s'ha definit l'etiqueta `<imatge>`:

```
<lloguer>
    <adreça>
        <carrer>Escudillers, 23</carrer>
        <ciutat>Figueres</ciutat>
        <codi_postal>17600</codi_postal>
    </adreça>
    <habitacio>
        <rect>
            <finestres>2<finestres>
            <portes>1</portes>
        </rect>
    </habitacio>
    <imatge>
        <svg>
            <rect x=0 y=0 width=30 height=60 />
        </svg>
    </imatge>
<lloguer>
```

Per un a lector humà en llegir-ho no hi hauria cap problema perquè ràpidament pot detectar que la imatge està dins de l'element `<imatge>`, però per a un programa, determinar si l'etiqueta és del vocabulari original o bé d'SVG, és pràcticament impossible. Això vol dir que cal algun sistema de poder definir a quin vocabulari pertanyen les etiquetes. Això és el que fan els **espais de noms**.

> Els espais de noms permeten mesclar llenguatges XML en el mateix document i a més definir clarament a quin vocabulari pertany cada etiqueta.

El que fan els espais de noms és canviar els noms de les etiquetes perquè siguin únics. En teoria es podria fer servir qualsevol combinació de caràcters, però com que hi hauria el mateix problema que amb les etiquetes (algú les podria usar) generalment es fa per mitjà d'una URL (*uniform resource locator*), que en principi són úniques. Així es podria definir una URL única al nostre espai de noms (`http://www.ioc.cat/lloguer`) i la URL d'SVG (`http://www.w3.org/2000/svg`) davant dels elements i el programa ja no tindrà problemes per determinar a quin vocabulari pertany cada etiqueta:

```
<http://www.ioc.cat/lloguer:lloguer>
    <http://www.ioc.cat/lloguer:adreça>
        <http://www.ioc.cat/lloguer:carrer>Escudillers, 23</http://www.ioc.cat/
            lloguer:carrer>
        <http://www.ioc.cat/lloguer:ciutat>Figueres</http://www.ioc.cat/
            lloguer:ciutat>
        <http://www.ioc.cat/lloguer:codi_postal>17600</http://www.ioc.cat/
            lloguer:codi_postal>
    </http://www.ioc.cat/lloguer:adreça>
    <http://www.ioc.cat/lloguer:habitacio>
        <http://www.ioc.cat/lloguer:rect>
            <http://www.ioc.cat/lloguer:finestres>2<http://www.ioc.cat/
                lloguer:finestres>
            <http://www.ioc.cat/lloguer:portes>1</http://www.ioc.cat/
                lloguer:portes>
        </http://www.ioc.cat/lloguer:rect>
    </http://www.ioc.cat/lloguer:habitacio>
    <http://www.ioc.cat/lloguer:imatge>
        <http://www.w3.org/2000/svg:svg>
            <http://www.w3.org/2000/svg:rect x=0 y=0 width=30 height=60 />
```

```
        </http://www.w3.org/2000/svg:svg>
    </http://www.ioc.cat/lloguer:imatge>
<http://www.ioc.cat/lloguer:lloguer>
```

Com que escriure totes les adreces cada vegada fa que es perdi la llegibilitat del document, l'XML permet definir àlies per a cada una de les URL. Els àlies es defineixen per mitjà de l'atribut `xmlns` dels elements i s'hereten a tot el contingut de l'element:

<element xmlns:alies="http://adreça"/> Per tant, si es defineix l'atribut en l'arrel del document s'heretaran els àlies a tots els elements del document.

```
<lloguer xmlns:lloguer="http://www.ioc.cat/lloguer"
         xmlns:svg="http://www.w3.org/2000/svg" >
    <lloguer:adreça>
        <lloguer:carrer>Escudillers, 23</lloguer:carrer>
        <lloguer:ciutat>Figueres</lloguer:ciutat>
        <lloguer:codi_postal>17600</lloguer:codi_postal>
    </lloguer:adreça>
    <lloguer:habitacio>
        <lloguer:rect>
            <lloguer:finestres>2<lloguer:finestres>
            <lloguer:portes>1</lloguer:portes>
        </lloguer:rect>
    </lloguer:habitacio>
    <lloguer:imatge>
        <svg:svg>
            <svg:rect x=0 y=0 width=30 height=60 />
        </svg>
    </lloguer:imatge>
<lloguer:lloguer>
```

`xmlns` també permet un espai de noms per defecte i que, per tant, podrà fer servir les seves etiquetes sense àlies. **Si algun atribut** `xmlns` **no defineix àlies es converteix en l'espai de noms per defecte**.

```
<lloguer xmlns="http://www.ioc.cat/lloguer"
         xmlns:svg="http://www.w3.org/2000/svg" >
    <adreça>
        <carrer>Escudillers, 23</carrer>
        <ciutat>Figueres</ciutat>
        <codi_postal>17600</codi_postal>
    </adreça>
    <habitacio>
        <rect>
            <finestres>2<finestres>
            <portes>1</portes>
        </rect>
    </habitacio>
    <imatge>
        <svg:svg>
            <svg:rect x=0 y=0 width=30 height=60 />
        </svg:svg>
    </imatge>
<lloguer>
```

Com que els espais de noms es poden definir en qualsevol element, una possibilitat alternativa seria **definir els espais de noms en les etiquetes adequades**:

```
<lloguer xmlns="http://www.ioc.cat/lloguer">
    <adreça>
        <carrer>Escudillers, 23</carrer>
```

```
        <ciutat>Figueres</ciutat>
        <codi_postal>17600</codi_postal>
    </adreça>
    <habitacio>
        <rect>
            <finestres>2<finestres>
            <portes>1</portes>
        </rect>
    </habitacio>
    <imatge>
        <svg xmlns="http://www.w3c.org/2000/svg">
            <rect x=0 y=0 width=30 height=60 />
        </svg>
    </imatge>
<lloguer>
```

D'aquesta manera tots els descendents de l'element <lloguer> segueixen el seu espai de noms excepte quan s'arriba a l'element <svg>, el qual canvia l'espai de noms per defecte per a ell i per als seus descendents.